

Software per statistica e econometria (autore: Vittorio Albertoni)

Introduzione

Con i vari linguaggi di programmazione detti all purpose, come C, Pascal, Python, Java, Julia, ecc., possiamo fare tutto ciò che vogliamo.

Alcuni di essi, come Python e Julia, vantano strumenti che facilitano i calcoli statistici e l'analisi dei dati in genere.

La situazione non era questa ai tempi in cui gli unici linguaggi disponibili per programmare calcoli erano il Fortran e il LISP, con i quali, specialmente con il secondo, era molto faticoso poter fare certe cose.

E' per questo motivo che, tra la fine degli anni '50 e la metà degli anni '70 del secolo scorso, vennero sviluppati software specializzati per calcoli statistici e analisi dei dati, come BMDP (Bio-medical Computer Programs) del 1957, SAS (Statistical Analysis System) del 1968, SPSS (Statistical Package for the Social Sciences) del 1968, Genstat del 1968, S del 1976, tutti software con licenza proprietaria.

Di questi, BMDP non è più sviluppato dal 2017, SAS, oltre che software per la statistica, è diventato il massimo nel campo dei Domain-Specific Languages per le materie cui ci stiamo riferendo e SPSS, con la sua interfaccia visiva a finestre e menu a tendina, comunque con la sua sintassi, lo segue da vicino; Genstat è pure ancora utilizzato da una nicchia nei settori dell'agricoltura, delle scienze biologiche e della ricerca bioscientifica. Sempre strumenti con licenza proprietaria e anche molto costosi.

Ad S, l'ultimo nato della serie sopra citata, viene comunque riconosciuta la primazia di linguaggio Domain-Specific per la statistica e da esso è stato derivato il software libero open source R, che, disponibile gratuitamente con licenza libera, sta soppiantando il suo genitore.

Col tempo, sempre nel mondo del software libero, sono nati strumenti tendenti a facilitare l'uso di R, come LabPlot e Jamovi, votati alla statistica.

Più rivolto all'econometria abbiamo un altro software, che comunque si può integrare con R, che si chiama Gretl.

In questo manualetto mi propongo semplicemente di mostrare a grandi linee il funzionamento di questi strumenti, con rimandi a fonti che, meglio di quanto possa fare io, descrivono nello specifico la sintassi dei vari comandi.

Il tutto senza dimenticare che, per l'analisi statistica, il calcolo numerico, la manipolazione dei dati e la visualizzazione grafica, con linguaggi come Python e Julia, possiamo fare le stesse cose praticamente con difficoltà non superiori.

Indice

I	R	4
1	Installazione	4
2	Come funziona	4
3	RStudio	6
4	R Commander	8
5	Spigolature	10
5.1	Grafici di funzione	10
5.2	Interfaccia grafica	12
II	LabPlot	15
1	Installazione	15
2	Come funziona	15
2.1	Foglio elettronico	16
2.2	Matrice	17
2.3	Foglio di lavoro	17
2.4	Cartella	17
2.5	Cartella di lavoro	17
3	A cosa serve	17
3.1	Elaborazioni sul foglio elettronico	17
3.2	Lavorare con il solo foglio di lavoro	18
3.3	Analisi di dati in serie	20
3.4	Tracciamento di grafici senza analisi	21
3.5	Tracciamento di grafici con analisi	21
4	Considerazioni conclusive	24
III	jamovi	26
1	Installazione	26
2	Come funziona	26
3	A cosa serve	27
3.1	Variabili	28
3.2	Dati	29
3.3	Analisi	29
3.4	Grafici	34
3.5	Modifica	34

IV	Gretl	35
1	Installazione	35
2	Come funziona	36
3	Caricamento dei dati	37
3.1	Immissione diretta	38
3.2	Importazione	38
4	Accuratezza numerica	39
5	Comandi e funzioni	39
6	Linguaggio HANSL	40
6.1	Interattività e script	40
6.2	Tipi e variabili	41
6.2.1	Tipi base	41
6.2.2	Tipi strutturati	42
6.2.3	Tipi legati al dataset	43
6.3	Operatori	44
6.3.1	Operatori aritmetici	44
6.3.2	Operatori di confronto	45
6.3.3	Operatori logici	45
6.4	Interattività con l'utente	45
6.5	Strutture di controllo	46
6.5.1	Esecuzione condizionale	46
6.5.2	Ripetizione	47
6.6	Creazione di funzioni	47
7	Grafica	49
8	Esempi di calcoli ed elaborazioni	49
8.1	Calcoli generici	49
8.2	Calcoli statistici	51
8.3	Calcoli econometrici	56

Parte I

R

Viene generalmente catalogato tra i linguaggi di programmazione ma io, come molti altri, preferisco vederlo come un ambiente, un environment, all'interno del quale possiamo fare soltanto determinate cose: nel caso specifico calcoli statistici di qualsiasi tipo.

Dal momento che per fare queste cose occorre richiamare funzioni che hanno un nome ed una sintassi di uso, hanno ragione anche quelli che lo vedono come un linguaggio.

R è stato derivato dal linguaggio S, nel 1996, dallo statistico neozelandese Ross Ihaka e dal matematico e statistico canadese Robert Gentleman, che hanno definito R "a language for data analysis and graphics", rendendolo software libero open source.

1 Installazione

All'indirizzo <https://cran.mirror.garr.it/CRAN/> troviamo i file per installare R sul nostro computer. Essi sono disponibili per i sistemi operativi Linux, Windows e Mac. Chi usa Linux può trovare quanto serve anche nel repository della sua distro.

L'installazione che avviene utilizzando questi file è già abbastanza ricca e comprende il package base, il package per la grafica e il package per il dataset.

Per le cose più sofisticate abbiamo a disposizione molti altri packages. All'indirizzo https://cran.r-project.org/web/packages/available_packages_by_name.html ne troviamo l'elenco e, cliccando sul nome che ci interessa, veniamo indirizzati a pagine che illustrano il singolo pacchetto, con indicazioni sulle modalità di uso.

L'installazione di un pacchetto avviene scrivendo il comando `install.packages("<nome_pacchetto>", dependencies=TRUE)` nella shell di R.

Dando invio dopo avere scritto il comando `install.packages()` senza indicare gli argomenti apriamo un elenco dal quale possiamo scegliere il pacchetto da installare.

Per la disinstallazione di un pacchetto usiamo il comando `remove.packages("<nome_pacchetto>")`.

Con il comando `library()` possiamo vedere l'elenco dei pacchetti installati.

2 Come funziona

Per lavorare con R si utilizza normalmente il terminale. Quello che in Linux e Mac si chiama proprio Terminale e che in Windows è sostituito dal così detto Prompt dei comandi, che non è utilizzabile per R.

Se lavoriamo su Linux o Mac, scrivendo a terminale il comando R si apre, nel terminale stesso, la shell di R, altrimenti detta console.


```
R version 4.1.2 (2021-11-01) -- "Bird Hippie"
Copyright (C) 2021 The R Foundation for Statistical Computing
Platform: x86_64-pc-linux-gnu (64-bit)

R è un software libero ed è rilasciato SENZA ALCUNA GARANZIA.
Siamo ben lieti se potrai ridistribuirlo, ma sotto certe condizioni.
Scrivi 'license()' o 'licence()' per maggiori dettagli.

R è un progetto collaborativo con molti contributi esterni.
Scrivi 'contributors()' per maggiori informazioni e 'citation()'
per sapere come citare R o i pacchetti nelle pubblicazioni.

Scrivi 'demo()' per una dimostrazione, 'help()' per la guida
oppure 'help.start()' per la guida nel browser HTML.
Scrivi 'q()' per uscire da R.
```

Se lavoriamo su Windows abbiamo a disposizione un launcher per aprire la R GUI



che contiene la console in un ambiente arricchito da un menu e da una barra di strumenti per fare alcune cose, tra cui, molto comoda, la voce PACCHETTI, che ci aiuta a installare i pacchetti.

In corrispondenza al prompt `>` si scrivono i comandi.

Ci viene ricordato che con il comando `q()` usciamo da R. Possiamo anche farlo con `ctrl-D`.

Ci vengono altresì suggeriti i comandi `demo()` e `help()`, convenientemente sostituibile da `help.start()`, molto utili per familiarizzare con R.

Con `demo()` ci vengono elencate le demo disponibili e per accedere alla demo dobbiamo indicarne il nome tra le parentesi.

Con `help()` ci viene spiegato come funziona l'help e inserendo il nome di un comando tra le parentesi ci viene spiegato il comando.

Con `help.start()` il sistema di help viene trasferito nel nostro browser web predefinito, dove, tra l'altro, troviamo un ottimo manuale introduttivo a R in lingua inglese.

Altro simpatico comando di didattica è `example()`. Se all'interno delle parentesi scriviamo il nome di un comando ci vengono proposte esemplificazioni del suo utilizzo.

Una volta scritto il comando in corrispondenza al prompt, alla pressione del tasto INVIO vediamo comparire il risultato fornito dal comando stesso.

Possiamo indicare più comandi sulla stessa riga separandoli con un punto e virgola (;) e alla pressione del tasto INVIO verranno eseguiti uno via l'altro mostrando i risultati.

Possiamo anche inserire nella shell di R uno script, cioè una serie di comandi che formano un programma, racchiudendo i comandi stessi da parentesi graffe ({ e }) e scrivendoli su righe separate.

Infine possiamo produrre uno script scrivendone i comandi con un editor di testo e salvare il tutto in un file con estensione `.R`. Lo script potrà essere eseguito quante volte vogliamo con il comando

```
source("<file.R>")
```

in corrispondenza al prompt `>` nella shell di R.

Se non siamo nella directory dove è stato salvato il file dobbiamo indicare tra gli apici il path al file stesso.

* * *

A questo punto subentra la necessità di conoscere i comandi da inserire nella shell o nello script e, per non ripetere inutilmente cose da altri scritte meglio di come possa fare io, suggerisco i seguenti tre indirizzi web:

<https://www.agnesevardanega.eu/wiki/r/start>

Dove troviamo un percorso completo per l'apprendimento di ciò che si può fare con R, proposto in lingua italiana a principianti niente meno che da una insegnante, Agnese Vardanega (meglio di così...) e fatto molto bene.

I contenuti che troviamo qui sono gli stessi proposti in un testo della stessa autrice «Ricerca sociale con R. Concetti e funzioni di base per l'analisi esplorativa dei dati», pubblicato attraverso StreetLib e reperibile in tutte le librerie on-line.

<https://cran.r-project.org/doc/contrib/Mineo-dispensaR.pdf>

Dove troviamo una ricca dispensa sull'utilizzo dell'ambiente statistico R.

<https://spout.ussg.indiana.edu/CRAN/doc/contrib/Frascati-FormularioStatisticaR.pdf>

Dove troviamo il catalogo completo delle funzioni statistiche, con l'indicazione del package di appartenenza, della formula sottostante la funzione, con la descrizione dell'output e con alcune esemplificazioni di utilizzo.

Molto altro si trova sul web su R, in lingua inglese ma spesso anche in lingua italiana.

3 RStudio

La modalità di lavorare con R in console vista nel precedente capitolo è la più ruspante e richiede una completa padronanza dei comandi e delle funzioni, dato che, mentre si lavora in console, diventa scomodo consultare l'help, salvo avere a disposizione un supporto cartaceo di consultazione.

Per agevolare non solo i principianti ma anche i professionisti c'è stato chi ha inventato una interfaccia grafica per lavorare con R, che si chiama RStudio.

Si tratta di una IDE (Integrated Development Environment) sviluppata a partire dal 2010 e rilasciata, anche con licenza libera, in prima versione il 1 novembre 2016.


Il suo uso presenta il grande vantaggio del controllo e dell'auto-completamento dei comandi che scriviamo, dell'immediatezza nell'accesso e nella consultazione dell'aiuto sulle funzioni e nella facilitazione nella gestione di oggetti e file di dati dall'area di lavoro.

Troviamo RStudio all'indirizzo www.rstudio.com e, se vogliamo risparmiare, dalla pagina DOWNLOAD possiamo scegliere RSTUDIO DESKTOP OPEN SOURCE LICENSE FREE DOWNLOAD e scaricare gli installer per il nostro sistema operativo (Linux, Windows o Mac).

Possiamo apprezzare il valore del software se diamo un'occhiata al prezzo dell'abbonamento annuale per le versioni commerciali corredate di vari livelli di assistenza e garanzia.

La versione gratuita libera è sempre rilasciata SENZA ALCUNA GARANZIA ma funziona bene pure lei se siamo in grado di farla funzionare, o solo con la nostra capacità o con l'aiuto di volontari appassionati che possiamo trovare sul web.

La finestra di lavoro di RStudio si presenta così



e, sotto la barra dei menu e degli strumenti, abbiamo quattro quadranti.

La barra dei menu è autoesplicativa.

Scorrendo il mouse sulle icone della sottostante barra degli strumenti abbiamo la descrizione di ciò che avviene cliccando sull'icona.

Il quadrante in basso a sinistra può aprirsi su tre schede.

Per default si apre sulla prima, denominata `CONSOLE`, che altro non è che la shell di cui abbiamo parlato nel precedente capitolo e come quella funziona.

Cliccando sulla linguetta di intestazione della seconda, denominata `TERMINAL`, apriamo il nostro terminale, dandoci la possibilità di fare altre cose intanto che lavoriamo su R.

Cliccando sulla linguetta di intestazione della terza, denominata `BACKGROUND JOBS`, apriamo una finestra nella quale possiamo lanciare elaborazioni in background. Il lancio avviene cliccando sul pulsante in alto a sinistra della finestra `START BACKGROUND JOB` e scegliendo il job da lanciare utilizzando la finestra di dialogo che si apre.

Il quadrante in alto a sinistra è un editor di script e vi possiamo inserire una serie di comandi per realizzare un progetto complesso.

E' dotato di una barra degli strumenti sulla quale abbiamo due pulsanti per eseguire lo script, in tutto o in parte.

Cliccando sul pulsante con la scritta `RUN` eseguiamo il contenuto della riga corrente o della parte selezionata dello script.

Cliccando sul pulsante con la scritta `SOURCE` eseguiamo tutto lo script.

Il risultato dell'elaborazione di parte o di tutto lo script compare nella sottostante `CONSOLE`.

Quando scriviamo i comandi in una di queste due finestre, Console e Editor, siamo aiutati dalla code completion e dalla comparsa di un help che ci guida all'inserimento dei parametri richiesti dalla funzione che stiamo attivando.

Nel quadrante in alto a destra si possono aprire quattro finestre.

La prima è denominata `ENVIRONMENT` ed è molto utile. La sua barra degli strumenti contiene alcune icone che si descrivono al passaggio del mouse. Aprendo quella denominata `IMPORT DATASET` abbiamo modo di organizzare l'importazione di dati da varie fonti. Sotto la barra degli strumenti abbiamo due pulsanti: il primo ci dà modo di scegliere se rimanere in R, posizione di default, o se dobbiamo collegarci a oggetti Python; il secondo ci dà modo di scegliere se il contenuto dell'environment debba essere evidenziato in modo globale, scelta di default, o limitatamente a un package. Nella zona sottostante verrà via via evidenziato ciò che succede nell'ambiente (environment) in cui stiamo lavorando: variabili create e loro valore, ecc.

La seconda è denominata `HISTORY` e vi si registra tutto ciò che facciamo.

La terza è denominata `CONNECTIONS` e serve per organizzare connessioni con basi di dati per alimentare il dataset.

La quarta è denominata `TUTORIAL` e serve per accedere a materiale educativo su R.

Abbiamo infine il ricco quadrante in basso a destra che si può aprire su sei finestre.

La prima, denominata `FILES`, ci dà modo di lavorare sul nostro file system per creare, spostare, cancellare files.

La seconda, denominata `PLOTS`, è dedicata a mostrare eventuali grafici prodotti nel corso del nostro lavoro.

La terza, denominata `PACKAGES`, elenca tutti i packages che abbiamo a disposizione: quelli che sono preceduti da un segno di spunta sono direttamente utilizzabili e quelli che sono preceduti da un quadratino vuoto vanno preventivamente caricati cliccando sul pulsante `INSTALL` (se produciamo uno script è bene che carichiamo il package che ci serve attraverso il comando `library(nome_pacchetto)` nella prima riga dello script stesso).

La quarta, denominata `HELP`, viene utilizzata per mostrare istruzioni sull'uso dei vari comandi e funzioni quando richiamate in approfondimento dell'help collegato alla code completion.

Le due rimanenti riguardano sofisticazioni per professionisti esperti.

Quello qui presentato è RStudio funzionante su un sistema Linux e chi lavora su Windows può trovare qualche differenza: la più vistosa è la mancanza della scheda Terminale nel quadrante in basso a sinistra (il Terminale esiste infatti solo in Linux e Mac).

4 R Commander

R Commander è una interfaccia grafica che si propone di consentire di lavorare con R, almeno di fare con R tantissime cose, senza conoscerne i comandi e la relativa sintassi.

Si tratta di un package di R, che va ovviamente installato dopo che è stato installato R, con il comando

```
install.packages("Rcmdr", dependencies=TRUE).
```

Chi lavora su Windows può aiutarsi con il menu PACCHETTI ▸ INSTALLA pacchetti della R Gui.


Chi lavora su Linux trova molto probabilmente il pacchetto nel repository della sua distro con il nome `rcmdr` e lo può installare con il gestore dei pacchetti.

Chi lavora su Mac deve innanzi tutto verificare che sul suo computer sia installato il sistema a finestre X11 (nella cartella UTILITY in APPLICAZIONI compare il file `X11.app`). Se `X11.app` manca, è possibile installarlo dal disco di installazione di Mac OS X. Inoltre è necessario successivamente installare Tcl/Tk procurandosi il file `TclTk-8.5.5-x11.dmg` all'indirizzo

<https://cran.r-project.org/bin/macosx/tools/>.

Infine si può procedere all'installazione di R Commander come visto fare per Linux e Windows.

La finestra di lavoro di R Commander è la seguente



Abbiamo una barra di menu autoesplicativa e, sotto, una barra di strumenti altrettanto autoesplicativa.

Ancora sotto abbiamo due finestre, una sopra l'altra. La prima, per default aperta sulla scheda SCRIPT DI R, la seconda dedicata ai RISULTATI.

Tra le due un pulsante ESEGUI, cliccando sul quale viene eseguito il contenuto della riga corrente nella finestra dello script o quanto selezionato dello script stesso, con evidenziazione di quanto fatto e del risultato nella finestra dei risultati.

Per esempio, se scriviamo nella finestra dello script la più elementare delle istruzioni

```
3 + 5
```

e con il cursore posizionato sulla stessa riga o avendo selezionato la riga stessa clicchiamo su ESEGUI, vedremo comparire nella finestra dei risultati quanto segue

```
> 3 + 5
```

```
[1] 8
```

cioè l'operazione svolta e il suo risultato, come se avessimo operato nella console.

In questo modo possiamo operare come se non utilizzassimo R Commander, scrivendo nella finestra dello script come se fossimo in R Studio.

Per lavorare con R Commander dobbiamo necessariamente avere caricato un set di dati: al lancio di R Commander notiamo nella finestrella SET DI DATI la scritta in rosso **<No active dataset>** e se scorriamo i menu troviamo la maggior parte delle voci disattivate.

Il caricamento dei dati avviene agendo sul menu DATI che ci dà modo di generare un set di dati o di importarlo (l'importazione da Excel richiede proprio un file Excel e se lavoriamo con Open Office o Libre Office dobbiamo salvare il file in quel formato per poterlo utilizzare).

A dati caricati tutte le voci dei menu sono attivate e possiamo eseguire i nostri calcoli avvalendoci di esse. Provvede R Commander a tradurre le nostre scelte in comandi riconosciuti, a compilare lo script, mostrandolo nella relativa finestra, e ad eseguirlo.

La citata guida a R della prof. Agnese Vardanega contiene un capitolo dedicato a R Commander.

Indubbiamente questo software alleggerisce di molto la fatica necessaria per usare R e consente di operare anche senza essere conoscitori dei vari comandi e della relativa sintassi ma, a volte, combina qualche scherzo e bisogna ricorrere a rimedi che comportano questa conoscenza.

Se, per esempio, abbiamo la seguente tabella, in un file `clientela.csv`, che evidenzia il numero dei clienti della nostra azienda nelle quattro città in cui opera

città	clienti
Milano	780
Roma	458
Torino	413
Genova	342

e vogliamo descrivere la distribuzione dei clienti in un grafico a torta utilizzando R Commander, dobbiamo importare i dati agendo da menu DATI > IMPORTA DATI > DA FILE DI TESTO... e scegliere il file `clientela.csv`.

Agendo da menu GRAFICI > GRAFICO A TORTA... siamo forzati a generare il seguente comando


```
with(Dataset, piechart(città, xlab="", ylab="", main="Distribuzione della clientela", col=rainbow_hcl(4), scale="percent"))
```

che non serve a nulla e genera un grafico insignificante.

Sapendo come funziona, sostituiamo a quel comando il seguente

```
with(clientela, pie(clienti, labels = città, main="Distribuzione della clientela", col=rainbow_hcl(4), scale="percent"))
```

ed otteniamo il grafico desiderato



Peccato! Perché quello della generazione di grafici è un grande punto di forza di R e proprio qui si trova una topicca di R Commander; spero non ce ne siano tante altre. Ciò serve comunque a dimostrare che gli automatismi spinti a volte creano qualche problema.

Tra l'altro avverto che R Commander è un software molto pesante e occupa quasi un Giga di spazio su disco.

5 Spigolature

Come ho detto, sul web esiste una vasta documentazione su R, anche in lingua italiana. Quella che ho richiamato specificamente nel Capitolo 2 è più che sufficiente per acquisire dimestichezza con questo software, avendo ovviamente anche la preparazione matematica e statistica per sapere che cosa si sta facendo.

Esplorando qua e là ho tuttavia notato scarsità di sottolineatura di alcune cosette abbastanza importanti che possiamo fare con R: la prima riguarda la facilità con cui possiamo creare grafici di funzioni matematiche, la seconda riguarda la possibilità di conferire interfaccia grafica a R attraverso il linguaggio Tcl/Tk (l'interfaccia di R Commander che abbiamo visto nel precedente capitolo è programmata in Tcl/Tk).

5.1 Grafici di funzione

La funzione `plot()` è delegata a produrre gran parte della vasta quantità di tipi di grafico che costituiscono uno dei punti di forza di R e il suo utilizzo richiede la conoscenza del significato di una miriade di parametri attraverso i quali ottenere grafici e loro caratteristiche.

Essa può essere utilizzata in modo facile, con pochi parametri, per creare grafici di funzione con la seguente sintassi:

```
plot(funzione, ascissa_iniziale, ascissa_finale, col = "...", main = "...")
```

in cui

`funzione` è il nome della funzione,

`ascissa_iniziale` e `ascissa_finale` indicano il campo di riferimento del grafico,

`col` indica il colore del grafico,

`main` indica il titolo del grafico,

solo i primi tre parametri sono necessari.


La funzione deve avere un nome per poterla richiamare come parametro.

Se la funzione è una di quelle preconfezionate in R, come `sin`, `cos`, `log`, ecc. abbiamo già il nome per richiamarla.

Il comando

```
plot(log, 0, 10)
```

produce questo grafico



Se la funzione non è tra quelle conosciute da R la creiamo noi assegnandola a un oggetto richiamabile con un nome.

La sintassi per creare l'oggetto funzione è

```
<nome> = function(x){  
  <espressione>  
}
```

dove

<nome> è il nome dell'oggetto funzione

<espressione> è la $f(x)$ di $y = f(x)$.

Se vogliamo tracciare il grafico della funzione

$$y = x^4 + 2x^3 - x - 5$$


creiamo la funzione f con

```
f = function(x){  
  x^4+2*x^3-x-5  
}
```

e la tracciamo con

```
plot(f, -2, 2)
```

ottenendo il grafico



Possiamo aggiungere una griglia al grafico utilizzando, insieme alla funzione `plot()` la funzione `grid()`, che ha la seguente sintassi

```
grid(nx=NULL, ny=NULL, col="...").
```


Con il seguente script

```
f <- function(x){  
  x^3-5*x-3  
}
```

```
plot(f, -2, 2, col="red", main="Grafico di y = x^3-5x-3")
```

```
grid(nx=NULL, ny=NULL, col="green")
```

otteniamo il grafico



5.2 Interfaccia grafica

Per quanto si possa considerare superfluo e inutilmente laborioso, R è attrezzato per potersi arricchire di interfaccia grafica, la così detta GUI.

A questo scopo esiste il package `tcltk` che utilizza il linguaggio di programmazione Tcl/Tk¹.


Un bell'esempio di applicazione R con GUI costruita con `tcltk` è R Commander, che abbiamo visto nel precedente capitolo.

Il package `tcltk` è presente nella dotazione di base di R ma deve essere caricato per essere utilizzato (è uno di quelli che nell'elenco gestito da RStudio ha il quadratino senza spunta).

Il suo utilizzo comporta ovviamente la conoscenza del linguaggio Tcl/Tk, anche se la sintassi dei vari comandi nell'embedding con R è alquanto diversa.

La finestra radice si crea con lo script


```
library(tcltk)
r = tktoplevel()
```



Aggiungendo allo script le istruzioni

```
tkwm.title(r,"PROVA")
f = tkframe(r, width=200, height=100, bg="yellow")
tkpack(f)
```

diamo un nome alla finestra e inseriamo nella finestra stessa un frame con colore di fondo giallo, largo 200 pixel e alto 100 pixel



Aggiungendo allo script le istruzioni

```
l = tklabel(f, text="CIAO", width = 20, padx=10, pady=10, bg="yellow", fg="red")
b = tkbutton(f, text="ESCI", bg="cyan", fg="blue")
tkpack(l, b)
otteniamo
```



Come si vede, con la sintassi sopra esemplificata e facilmente estensibile a tutti gli widget, li possiamo creare e collocare osservando che il loro nome e i comandi per collocarli sono gli stessi del linguaggio Tcl/Tk preceduti dal prefisso `tk` (`button` diventa `tkbutton`, `pack` diventa `tkpack`, ecc.).

Per quanto riguarda i dati da trattare, il linguaggio Tcl/Tk si presta all'acquisizione dei dati dalla tastiera ma, per poterli lavorare con le funzioni di R dobbiamo applicare il seguente trucco

¹Per una introduzione a questo linguaggio consiglio il manualetto «`tcl_tk`» allegato al mio articolo «Tcl/Tk: un tesoro nascosto» pubblicato nel dicembre 2019 sul mio blog all'indirizzo www.vital.it. Lo stesso contenuto si trova nel volumetto «Programmazione con Tcl/Tk» acquistabile su Amazon.


. creiamo una variabile per l'ambiente Tcl con la funzione di R `tclVar()`
`x = tclVar(8)`
 crea la variabile x per l'ambiente Tcl e vi inserisce il valore 8
 . per poter utilizzare nell'ambiente R questo valore ricorriamo alla funzione di R `tclvalue()`
`y = tclvalue(x)`
 crea la variabile y per l'ambiente R e, dal momento che in Tcl tutto è stringa, vi inserisce il valore stringa "8".
 Per inserire nella variabile y questo valore come numero dobbiamo ricorrere al casting
`y = as.numeric(tclvalue(x))`

Il seguente script esemplifica un po' tutto

```
library(tcltk)
r = tktoplevel()
tkwm.title(r, "MEDIA E VARIANZA")
x = tclVar("")
v = c()
e = tkentry(r, width=10, textvariable=x)
tkpack(e, pady=5)
tkfocus(e)
immetti = function(){
  xx = as.numeric(tclvalue(x))
  v <- c(v, xx)
  tkdelete(e, 0, 10)
  tkfocus(e)
}
b = tkbutton(r, text="IMMETTI", command=immetti)
tkpack(b, pady=2)
calcola = function(){
  m <- mean(v)
  vc <- var(v)
  vp <- vc*(length(v)-1)/length(v)
  tkconfigure(l2, text=m)
  tkconfigure(l4, text=vc)
  tkconfigure(l6, text=vp)
  tkmessageBox(title="DATI", message=paste(v))
}
b2 = tkbutton(r, text="CALCOLA", command=calcola)
tkpack(b2, pady=2)
l1 = tklabel(r, text="Media")
tkpack(l1, pady=2)
l2 = tklabel(r)
tkpack(l2)
l3 = tklabel(r, text="Varianza campionaria")
tkpack(l3, padx=35, pady=2)
l4 = tklabel(r)
tkpack(l4)
l5 = tklabel(r, text="Varianza popolazione")
tkpack(l5, pady=2)
l6=tklabel(r)
tkpack(l6)
```

Con questo script possiamo calcolare la media e la varianza di una serie di dati con il software R senza conoscere nulla di questo software.


Memorizzato lo script in un file `prova.R`, se lo lanciamo dalla console compare la seguente finestra



The dialog box titled 'MEDIA E VARIANZA' contains a text input field at the top. Below it are two buttons: 'IMMETTI' and 'CALCOLA'. At the bottom, there are three labels: 'Media', 'Varianza campionaria', and 'Varianza popolazione'.

L'utente inserisce i dati della serie di cui vuole calcolare media e varianza, uno per uno, nella finestrella cliccando sul pulsante IMMETTI per ciascuno di essi. Alla fine, cliccando sul pulsante CALCOLA, ottiene quanto richiesto, con un messaggio riepilogativo dei dati immessi.

Se, per esempio, inseriamo la serie 1 2 3 4 5 otteniamo



The image shows two overlapping dialog boxes. The 'DATI' dialog box on the left has a lightbulb icon and displays the numbers '1 2 3 4 5' with an 'OK' button below. The 'MEDIA E VARIANZA' dialog box on the right shows the results of the calculation: 'Media' is 3, 'Varianza campionaria' is 2.5, and 'Varianza popolazione' is 2. It also has 'IMMETTI' and 'CALCOLA' buttons.

Parte II

LabPlot

LabPlot è specializzato nell'analisi e nella descrizione in termini matematico-statistici dei dati e lo fa con insuperata velocità di realizzazione e con una impostazione interattiva che non è appannaggio dei fogli di calcolo e tanto meno dei linguaggi di programmazione. Tra l'altro con risibile assorbimento di risorse.

La descrizione dei dati non è tanto e soltanto di tipo visivo.

Dove LabPlot dà il meglio è nella produzione di elementi descrittivi attraverso indicatori statistici e attraverso l'individuazione di relazioni di tipo matematico tra dati, anche ben visualizzate con grafici di tipo cartesiano molto ben fatti.

Quando, all'inizio del secolo, Stefan Gerlach e la sua squadra di sviluppatori della comunità KDE iniziarono a lavorare su LabPlot si ispirarono ad un software commerciale distribuito alcuni anni prima dalla Microcal Software (poi divenuta OriginLab Corporation) e nato per elaborare i dati generati dai microcalorimetri prodotti dalla MicroCal Inc.

Tuttora questo software proprietario è distribuito come Origin e Origin Pro, e costa pure parecchio.

LabPlot, il cui primo rilascio è avvenuto nel 2003 e la cui prima versione completa risale al 2008, dopo la sua unificazione con il software SciDAVis, altro vero e proprio clone di Origin, passa per essere la versione libera di questo software commerciale.

Occorre tuttavia riconoscere a Origin qualche punto in più nella produzione di grafici statistici.

Qui mi pongo l'obiettivo di descrivere le basi per avviarsi all'utilizzo del software, in modo che il lettore possa poi gradualmente diventare un esperto attraverso varie sperimentazioni.

Nella documentazione KDE si trova un ricco manuale, anche tradotto in italiano, con cui possiamo saperne di più.

In ogni caso si dà per scontato che il lettore abbia una certa familiarità con gli strumenti matematico-statistici messi a disposizione: dal sapere la differenza tra la media aritmetica e la media geometrica al sapere la differenza tra una curva esponenziale e una curva polinomiale.

1 Installazione

Troviamo LabPlot all'indirizzo <https://labplot.org/>.


Nella pagina DOWNLOAD possiamo scegliere il sistema operativo e troviamo gli installer per Windows e Mac. Per Linux ci viene proposta una AppImage e pacchetti Flatpak o Snap.

Possiamo comunque sicuramente trovare LabPlot nel repository della nostra distro, ovviamente senza pretendere che sia l'ultimo rilascio. In certi casi, come in MXLinux e altro di derivazione Debian può non funzionare e occorre ripiegare su AppImage o Flatpak.

Nella pagina DOCUMENTATION si trova un ottimo manuale, forse meglio di quello che troviamo nella documentazione KDE, purtroppo solo in lingua inglese.

2 Come funziona

Al lancio del programma ci si presenta questa finestra



In alto abbiamo le solite barre di menu, autoesplicativa, e strumenti, con icone su cui possiamo passare il puntatore del mouse per avere contezza delle funzioni sottese.

Sotto abbiamo tre finestre.

La finestra sulla sinistra è l'ESPLORATORE DEI PROGETTI e mostra, con un sistema ad albero, tutti i componenti del progetto.

Cliccando destro sulla voce PROGETTO e poi puntando il mouse su AGGIUNGI NUOVO apriamo un menu a discesa da cui possiamo scegliere il componente da aggiungere.

Cliccando destro su un componente elencato apriamo un menu a discesa da cui possiamo scegliere alcuni interventi, tra cui quello di eliminare il componente dal progetto.

La finestra sulla destra è quella delle PROPRIETÀ, riferite al componente visualizzato nella finestra centrale.

La finestra centrale visualizza il componente su cui stiamo lavorando e possiamo scegliere quale visualizzare cliccando sul relativo nome nella finestra dell'esploratore di progetti oppure sul relativo nome nella barretta in alto nella finestra centrale.

L'immagine mostra le finestre compattate sotto la barra di menu ma chi usa uno schermo sufficientemente grande può utilmente scompattarle e posizionarle separate sullo schermo rendendo così più agevole lavorare.

Ora vediamo i componenti con cui possiamo lavorare.

2.1 Foglio elettronico

E' il contenitore dei dati da elaborare e non ha niente a che vedere con i fogli di calcolo tipo Excel, Calc, ecc., universalmente noti pure come fogli elettronici.

Quello di LabPlot è organizzato su colonne affiancate, ognuna delle quali contiene una serie di dati.

L'inserimento dei dati può avvenire manualmente attraverso la tastiera, riga per riga, oppure può avvenire con copia e incolla da un foglio di calcolo o, ancora, per importazione da un file ASCII di tipo csv o altra fonte agendo da menu FILE > IMPORTA.

Per default ogni colonna è predisposta a contenere dati di tipo double (numeri a virgola mobile in doppia precisione), tradotto in italiano con il termine «doppia» che compare nell'intestazione delle colonne.

Cliccando sull'intestazione della colonna apriamo sulla destra la finestra PROPRIETÀ: COLONNA nella quale possiamo modificare il tipo di dato agendo sulla finestrella TIPO.

Cliccando destro sulla barra delle intestazioni delle colonne apriamo un menu a discesa utilizzando il quale possiamo inserire altre colonne.

Possiamo anche creare colonne contenenti serie di dati calcolate applicando formule alla o alle serie di dati contenuti in altre colonne.

2.2 Matrice

E' un contenitore di dati organizzato per contenere non semplici serie di dati ma griglie di valori.

Questo potrebbe essere un esempio di matrice che contiene le temperature su una piastra in varie posizioni, rappresentate dalle coordinate corrispondenti alle intestazioni di righe e colonne.

Matrice ×			
	1	2	3
1	50,00	52,00	55,00
2	53,00	54,00	58,00
3	60,00	58,00	62,00

L'esempio non è casuale e si ricollega al fatto che il software Origin cui LabPlot si ispira era nato per elaborare i dati generati dai microcalorimetri prodotti dalla MicroCal Inc.

2.3 Foglio di lavoro

E' dove si lavora con i numeri ed è usato per

- . analisi,
- . grafici,
- . andamento dei dati (fitting),
- . operazioni matematiche.

2.4 Cartella

E' un contenitore organizzativo e non ha contenuto scientifico.

2.5 Cartella di lavoro

E' un contenitore di fogli di lavoro, destinato a raggruppare più fogli di lavoro appartenenti allo stesso contesto.

3 A cosa serve

Passiamo ora in rassegna le più comuni potenzialità di LabPlot nel trattamento di dati.

3.1 Elaborazioni sul foglio elettronico

Ho detto prima che il foglio elettronico di LabPlot non è esattamente un foglio di calcolo.

Lo può tuttavia essere, a modo suo, in quanto possiamo eseguirvi calcoli inserendo formule, non già avendo come base di input e output anche caselle singole come avviene nei fogli di calcolo, ma avendo come base di input e output intere colonne.

A questo fine, dopo che abbiamo alimentato il foglio con dati, inseriti da tastiera o importati, creiamo una nuova colonna destinata a contenere dati calcolati, clicchiamo destro sulla sua intestazione e scegliamo la voce **GENERA I DATI** nel menu a discesa e poi la voce **VALORI DELLA FUNZIONE** aprendo così questa finestra



Nella zona **VARIABILE**, cliccando sul pulsante **+**, definiamo la o le variabili attribuendo loro un nome e facendole corrispondere al numero della colonna contenente le relative serie di dati e nella zona **FUNZIONE** scriviamo la formula utilizzando i nomi delle variabili definite.

Per esempio, avendo nel foglio due colonne di dati identificate dai numeri 1 e 2, creiamo una terza colonna per i dati calcolati e, dopo aver definito due variabili, x e y , facendo loro corrispondere, rispettivamente, le colonne 1 e 2, inseriamo la formula $x+y$ e, cliccando sul pulsante **GENERA** in fondo a destra della finestra sopra illustrata, in questa terza colonna troveremo la somma dei dati delle prime due.

Oltre che formule create da noi, utilizzando i soliti operatori aritmetici $+$ $-$ $*$ $/$ e $^$ per l'elevamento a potenza, possiamo utilizzare l'ampia gamma di funzioni precostituite in LabPlot: esse sono elencate nel paragrafo 10 del manuale, che possiamo aprire premendo il tasto **F1** o da menu **AIUTO** $\triangleright$ **MANUALE DI LABPLOT**, con il titolo «Funzioni di elaborazione» («Parser function» per chi non riesca a trovare il manuale in lingua italiana).

3.2 Lavorare con il solo foglio di lavoro

Visto che abbiamo a che fare con un software che crea grafici, possiamo utilizzarlo per tracciare grafici di funzioni matematiche; in questo caso senza bisogno di utilizzare dati precedentemente inseriti nel foglio elettronico ma operando direttamente sul foglio di lavoro con l'indicazione della funzione di cui tracciare il grafico.


Clicchiamo destro sulla voce **PROGETTO** nella finestra dell'esploratore dei progetti e poi scegliamo **AGGIUNGI NUOVO** e **FOGLIO DI LAVORO**.

Poi clicchiamo destro sulla voce **FOGLIO DI LAVORO** (oppure nella finestra centrale dove si trova il foglio di lavoro) e poi scegliamo **AGGIUNGI NUOVO**, **AREA DEL GRAFICO** e **DUE ASSI, INCROCIATI NELL'ORIGINE**.

Nel foglio di lavoro che abbiamo nella finestra centrale compare un piano cartesiano con i due assi estesi tra i valori di default $-0,5$ e $0,5$, che non si capisce perché siano stati scelti così bassi.

Agendo nella finestra contraddistinta dalla linguetta **GENERALE** della finestra delle proprietà riferita all'area del grafico, interveniamo nelle zone **INTERVALLO X** e **INTERVALLO Y**, deselezionando la voce **AUTOMATICO** e inserendo valori un tantino più abbondanti, per esempio -10 e 10 , rispettivamente nelle finestrelle **INIZIO** e **FINE**.

Così ci troviamo nel foglio di lavoro questo piano cartesiano



Se riteniamo di alleggerire il peso dei caratteri delle etichette sugli assi possiamo modificarne la dimensione cliccando sull'asse orizzontale della X e agendo nella finestrella CARATTERE della finestra delle proprietà, ripetendo poi l'operazione per l'asse delle Y.

A questo punto non ci resta che indicare la funzione di cui tracciare il grafico e lo facciamo cliccando destro sulla voce AREA DEL GRAFICO nella finestra dell'esploratore dei progetti (oppure all'interno dell'area del grafico nella finestra del foglio di lavoro) scegliendo poi AGGIUNGI NUOVO e GRAFICO DELLA FORMULA.


Nella finestra delle proprietà, zona EQUAZIONE, manteniamo la scelta di default CARTESIANO nella finestrella del TIPO (alternativamente potremmo scegliere POLARE o PARAMETRICO) e scriviamo la formula della funzione da tracciare nella finestra a lato della scritta $y = f(x)$, per esempio:

$$x^3 + 4x^2 + x - 3$$

Infine indichiamo con -10 e 10, coerentemente con lo schema cartesiano prima creato, i limiti X, MINIMO e X, MASSIMO nelle rispettive finestrelle.

Manteniamo il suggerimento di default 1000 nella finestrella PUNTI (più è grande questo numero più sarà liscia la curva disegnata) e clicchiamo sul pulsante RICALCOLA.

Otteniamo così questo grafico



Sarebbe bello inserire un titolo e lo facciamo cliccando sulla zona del grafico nel foglio di lavoro e aprendo la finestra con la linguetta TITOLO nella finestra delle proprietà.

Nella zona TESTO, finestrella MODALITÀ, ci conviene scegliere l'opzione MARKDOWN, in modo da poter scrivere la formula con l'elevamento a potenza come si deve.

Nella finestrella vuota sotto la piccola barra di strumenti inseriamo la dicitura


Grafico di $y = x^3 + 4x^2 + x - 3$

e scegliamo il font e corpo nella sottostante finestrella CARATTERE PRINCIPALE.

Sempre da menu FILE, con STAMPA possiamo stampare il foglio di lavoro con il grafico e con SALVA possiamo salvare il progetto su un file di formato .lml.

Clicchiamo ora sulla linguetta che apre la sotto-finestra DISPOSIZIONE della finestra delle proprietà dell'area del grafico e regoliamo la spaziatura indicando 1 cm nella finestrella ALTO della zona SPAZIATURA.

Possiamo così finalmente ammirare il nostro prodotto finito



Da menu FILE ► ESPORTA... possiamo esportare il file contenente il grafico scegliendo uno dei tanti formati disponibili.

Sempre da menu FILE, con STAMPA possiamo stampare il foglio di lavoro con il grafico e con SALVA possiamo salvare il progetto su un file di formato .lml.

Nell'esempio ho indicato una funzione scrivendola in formula ma, per le funzioni precostituite in LabPlot cui ho accennato alla fine del precedente paragrafo, potremmo scrivere semplicemente il nome della funzione, in ciò aiutati da una ottima code completion.

3.3 Analisi di dati in serie

Una serie di dati occupa una colonna del foglio elettronico.

Selezionata la colonna possiamo ottenere tutta una serie di indicazioni di statistica descrittiva sui dati che contiene cliccando destro sulla colonna stessa e scegliendo nel menu a discesa la voce STATISTICHE SULLE COLONNE...


Il tutto occupa una finestra il cui schema è illustrato all'inizio della prossima pagina.

Notiamo in alto a sinistra la linguetta 1. Se selezionassimo più colonne nel nostro foglio elettronico otterremmo più tavole di risultati, ciascuna contrassegnata con una linguetta con il numero corrispondente alla colonna di riferimento.

La parte superiore della finestra contiene un grafico che, alla linguetta PANORAMICA, corrisponde al grafico sparkline dei dati inseriti nella colonna avendo sull'asse delle ascisse l'indice di riga (partendo da 0 per la riga 1) e sull'asse delle ordinate il valore del dato.

Agendo sulle linguette successive (ISTOGRAMMA, GRAFICO KDE (Kernel Density Estimator), GRAFICO Q-Q NORMALE e GRAFICO A SCATOLA) otteniamo altrettanti grafici che illustrano come sono distribuiti i dati della serie analizzata.

A seguire i vari indicatori di statistica descrittiva.



3.4 Tracciamento di grafici senza analisi

In presenza di un foglio elettronico con due colonne contenenti entrambe dati numerici possiamo tracciare parecchio tipi di grafico aventi sull'asse delle ascisse i dati della colonna 1 e sull'asse delle ordinate i dati della colonna 2.

Per farlo clicchiamo destro sulla voce FOGLIO ELETTRONICO nella finestra dell'esploratore dei progetti oppure sul foglio interamente selezionato nella finestra di lavoro centrale e puntiamo il cursore del mouse sulla voce TRACCIA DATI del menu a discesa che si apre.

Dall'elenco che si apre a lato di questa voce scegliamo il tipo di grafico che intendiamo tracciare (A LINEA, A DISPERSIONE, A LINEE E SIMBOLI, STATISTICI come l'istogramma o A MIGLIORAMENTO CONTINUO), tenendo presente che il solo tipo che si adatta al caso in cui la prima colonna non contenga dati numerici ma etichette di testo (come avviene, per esempio, nelle serie temporali) è il grafico così detto a miglioramento continuo.

3.5 Tracciamento di grafici con analisi

E' dove LabPlot manifesta la sua vera potenza.

Sempre in presenza di un foglio elettronico con due colonne contenenti entrambe dati numerici possiamo tracciare parecchi tipi di grafico previa analisi ed elaborazione statistica dei dati stessi.

A volte si tratta di grafici nei quali, oltre ad essere rappresentati i dati come avviene nei grafici di cui al paragrafo precedente, viene delineata una linea o una curva interpolatrice dei dati stes-

si, che rappresenta il grafico della funzione matematica indicante la presunta relazione esistente tra i dati della prima colonna e i dati della seconda colonna del foglio elettronico, come avviene nell'adattamento (in inglese fitting).

Altre volte si tratta di analisi tendenti a semplificare, sintetizzandolo, il grafico dei dati originali, come avviene per la smussatura a medie mobili.

Altre volte ancora si tratta di analisi tendenti a mostrare in grafico velocità di variazione dei dati, come avviene nella derivazione e nell'integrazione.

Per ottenere tutto questo clicchiamo destro sulla voce FOGLIO ELETTRONICO nella finestra dell'esploratore dei progetti oppure sul foglio interamente selezionato nella finestra di lavoro centrale e puntiamo il cursore del mouse sulla voce TRACCIA DATI del menu a discesa che si apre.

In questo menu abbiamo le voci

ADATTA (in inglese Fitting)

ADATTA DISTRIBUZIONE (in inglese Curve Fitting)

DERIVA (in inglese Differentiation)

INTEGRA (in inglese Integration)

INTERPOLA (in inglese Interpolation)

SMUSSATURA (in inglese Smoothing)

FILTRO DI FOURIER (in inglese Fourier Filter)

RIDUCE I DATI (in inglese Data Reduction)

Ho riportato tra parentesi le dizioni inglesi di questi termini per un utile riferimento al manuale inglese o al caso di avere a disposizione un software con GUI non tradotta.

Per vedere come funziona ritengo utile un esempio riguardante l'uso della prima di queste voci, che è la più rappresentativa e la più ricca di risultato, sia sul piano grafico sia sul piano analitico.


Poniamo di avere questo foglio elettronico

	1 {Doppia} [X]	2 {Doppia} [Y]
1	2,5	16
2	4	12,7
3	6,7	4
4	8	2
5	12	15
6	14,5	24
7	17	37,1
8	22	31
9	23,2	22
10	28	12
11	32	7,8
12	37	5
13	-	-

Richiamo l'attenzione sul fatto che il separatore decimale è la virgola in quanto il software è caricato su un sistema operativo configurato per la lingua italiana e LabPlot si adegua.

Ci poniamo l'obiettivo di trovare una funzione matematica che rappresenti nella maniera più precisa possibile la relazione esistente tra i dati della colonna 1 e i dati della colonna 2, rappresentandone il grafico insieme a quello dei dati originari.

Cominciamo con il tracciare i dati originari, cliccando destro sulla voce FOGLIO ELETTRONICO nell'esploratore dei progetti e poi selezionando TRACCIA I DATI ▷ LINEA DEI GRAFICI ▷ LINEA e otteniamo



Poi clicchiamo destro sulla voce FOGLIO ELETTRONICO nella finestra dell'Esploratore dei progetti e poi scegliamo ANALIZZA E TRACCIA I DATI ▷ ADATTA.

Ci viene proposta la scelta di una serie di tipi di funzione cui ispirarci per la nostra ricerca:

LINEARE, del tipo polinomiale $y = a + bx + cx^2 + \dots$

POTENZA, del tipo $y = ax^b$

ESPONENZIALE (GRADO1), del tipo $y = ae^{bx}$

ESPONENZIALE (GRADO 2). del tipo $y = a_1e^{b_1x} + a_2e^{b_2x}$

ESPONENZIALE INVERSA, del tipo $y = a(1 - e^{bx}) + c$

GAUSS, del tipo $y = \frac{A}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$

CAUCHY-LORENTZ, del tipo $y = \frac{A}{\pi\gamma(1+(\frac{x-\mu}{\gamma})^2)}$

ARCOTANGENTE. del tipo $y = A \arctan(\frac{x-\mu}{\sigma})$

TANGENTE IPERBOLICA, del tipo $y = A \tanh(\frac{x-\mu}{\sigma})$

FUNZIONE DEGLI ERRORI, del tipo $y = \frac{A}{2} \operatorname{erf}(\frac{x-\mu}{\sqrt{2}\sigma})$

Come non bastasse la lista si conclude con la voce PERSONALIZZATO per darci modo di poter scegliere una funzione di nostra creazione.


Cominciamo dalla più semplice: clicchiamo su LINEARE e proseguiamo accettando il default che ci viene proposto nella successiva finestra.

In questo modo creiamo una interpolante di tipo polinomio di primo grado, cioè una retta e, data la forma del grafico dei dati originari, sicuramente non ci siamo.

Allora andiamo nella finestra dell'Esploratore dei progetti e apriamo la voce AREA DEL GRAFICO cliccando sul simbolo > alla sua sinistra e poi clicchiamo sulla voce ADATTA A «2».

Ora ci trasferiamo nella finestra delle Proprietà di Adatta e nella zona ADATTA eleviamo gradualmente il numero inserito nella finestrella GRADI ogni volta cliccando sul pulsante ESEGUI appena sotto la sottostante zona PARAMETRI.

In questo modo vediamo nel grafico dell'area di lavoro centrale disegnarsi una curva sempre più accostata al tracciato dei dati originali fino al raggiungimento della quasi perfezione in corrispondenza del numero 7



Nella zona PARAMETRI della finestra delle Proprietà dell'area del grafico troviamo elencati i parametri che caratterizzano il polinomio di settimo grado interpolante che possiamo scrivere così

$$y = -21,3798 + 33,7827x - 10,4747x^2 + 1,3507x^3 - 0,0849673x^4 + 0,00278418x^5 - 4,58599E-05x^6 + 3,00631E-7x^7$$

Se nella finestra dell'Esploratore dei progetti apriamo la voce ADATTA A «2» cliccando sul simbolo > alla sua sinistra e poi clicchiamo sulla voce RISULTATI DELL'ADATTAMENTO, nell'area di lavoro centrale troviamo la descrizione del polinomio interpolante con i parametri già visti prima e, nella zona BONTA' DI ADATTAMENTO, tutta una serie di indicatori statistici sull'attendibilità di quanto abbiamo fatto, compreso un coefficiente di determinazione pari a 0,978155 a dimostrazione della grande approssimazione raggiunta.

Lascio al lettore il divertimento di provare altri approcci utilizzando funzioni di tipo diverso dalla polinomiale ma penso che, per i dati su cui lavoriamo, non si trovi di meglio.

4 Considerazioni conclusive

Dalla panoramica presentata in questo manualetto penso si sia compreso che, dal momento che il fine primario di LabPlot è quello di tracciare grafici a due dimensioni, tutta l'analisi retrostante, pur fatta bene, è finalizzata alle due dimensioni dei grafici tracciabili.

Pertanto non possiamo individuare con LabPlot legami tra una serie di dati e più serie di dati, come si fa nella così detta regressione multipla: tutto ciò che facciamo con LabPlot lo facciamo al massimo coinvolgendo due serie di dati, cioè due colonne del foglio elettronico.

Gli indicatori di statistica descrittiva coinvolgono addirittura una sola colonna del foglio elettronico.

Pertanto importanti indicatori che coinvolgono anche solo due colonne, come il coefficiente di correlazione, non li troviamo in LabPlot.

Parte III

jamovi

jamovi si ispira e si pone come contraltare libero di SPSS e SAS e, programmato in C++ e Javascript, utilizza il linguaggio R per le elaborazioni statistiche.

La sua nascita si deve agli sviluppatori Jonathon Love, Damian Dropmann e Ravi Selker, già sviluppatori del progetto JASP presso l'Università di Amsterdam, che riguarda un software pure open source di cui jamovi è praticamente una copia.

I suoi sviluppatori raccomandano di scriverne il nome in lettere minuscole, nonostante si tratti dell'acronimo di Just Another Multivariate Open-source Visual Interface.

E' distribuito dal 2017 ed offre maggiore estensibilità tramite moduli, una gestione dati superiore e una più stretta integrazione con R rispetto al suo simile JASP, distribuito dal 2015.

jamovi è un ottimo strumento didattico e di analisi. Non serve per complessi modelli multilevel, modelli misti con strutture di covarianza particolari, analisi con specificazioni non standard o altamente personalizzate. In questi casi è meglio R puro o, meglio ancora, Python.

Altro importante limite è dato dal fatto che jamovi lavora totalmente in memoria RAM per cui non è adatto per computer con meno di 4 GB di RAM e per affrontare analisi su grandi masse di dati, meno che mai se pensiamo ai big data, campo in cui dobbiamo ricorrere a R ottimizzato o all'insuperabile Python.


1 Installazione

Troviamo jamovi all'indirizzo <https://www.jamovi.org/>, dove ci viene proposto l'uso in cloud o l'installazione.

Per l'installazione clicchiamo sul pulsante Download Desktop e andiamo all'indirizzo <https://www.jamovi.org/download.html> dove troviamo gli installer per Windows e Mac e il package flatpak per Linux.

2 Come funziona

jamovi si apre con questa finestra



che corrisponde alla scelta della linguetta ANALISI nella barra dei menu.

In corrispondenza a questa scelta la sottostante barra degli strumenti contiene icone corrispondenti ai tipi di analisi possibili.

Richiamo l'attenzione sull'ultima icona sulla destra del gruppo, che si riferisce al linguaggio R e che apre un editor per questo linguaggio, utilizzabile per scrivere comandi in linguaggio R per fare cose non previste dai richiami visuali attraverso le icone.

Essa non è presente per default ma si può avere caricando preventivamente un modulo apposito, ed è ciò che consiglio di fare per avere una completezza di strumenti di base.

A questo scopo si clicca sul pulsante con l'icona e la scritta MODULI in fondo a destra della barra degli strumenti, si sceglie LIBRERIE JAMOVİ e si installa il primo modulo che compare nella lista, RJ EDITOR.

Sempre agendo sull'icona e la scritta MODULI in fondo a destra della barra degli strumenti possiamo installare altri moduli in arricchimento delle prestazioni di base di jamovi, già notevoli e più che sufficienti per la comunità di dilettanti evoluti cui dedico i miei manuali.

In corrispondenza alle altre linguette (VARIABILI, DATI, GRAFICI e MODIFICA) abbiamo altre icone corrispondenti alle azioni possibili.

In ogni caso, delle due grandi finestre sottostanti le barre del menu e degli strumenti, quella di sinistra è destinata alle elaborazioni da impostare e quella di destra è destinata a mostrare il risultato delle elaborazioni.

Cliccando sulla prima icona della barra del menu, quella contrassegnata da tre barrette orizzontali sovrapposte, apriamo un menu da cui possiamo avviare un nuovo progetto, possiamo salvare il progetto in lavorazione e possiamo esportare l'intero contenuto della finestra dei risultati in formato PDF. Agendo sulla scelta del formato di esportazione possiamo esportare coerenti contenuti del progetto in formati adatti ai fogli di calcolo Calc e Excel e a molti altri formati, compresi quelli per interscambio con i software SPSS e SAS.

Per esportare zone selezionate della finestra dei risultati occorre selezionarle agendo con il cursore del mouse e, cliccando destro all'interno dell'area selezionata, scegliere il formato del file esportato.

Cliccando sulla voce APRI dello stesso menu possiamo aprire progetti salvati o importare dati da altre fonti, compresi i fogli di calcolo Calc e Excel e altri formati, compresi quelli per interscambio con i software SPSS e SAS.

3 A cosa serve

Come ormai si sarà compreso, jamovi è un software che ci consente di fare tante cose utilizzando il motore di calcolo statistico R in modo visuale, cioè senza scrivere codice.

Con le estensioni installabili possiamo fare altre cose, sempre in formato visuale.

Se tutto ciò non basta abbiamo a disposizione l'editor per scrivere istruzioni in linguaggio R ed eseguirle grazie all'editor installabile, come abbiamo visto, attraverso modulo aggiuntivo.

Da sapere che per lavorare con jamovi non abbiamo bisogno di installare anche R sul computer, in quanto jamovi ha al suo interno un motore R più che sufficiente per analisi anche molto impegnative.

Certo che, installando R puro e R ottimizzato possiamo andare anche oltre e, come ho detto in premessa, affrontare anche elaborazioni nel campo dei big data, sempre sapendo che non arriveremo mai a fare ciò che si può fare con Python.

C'è chi dice che R non è un motore big data ma è un cervello statistico e che si usa per pensare, non per spostare montagne.

Passiamo ora in rassegna tutto ciò che possiamo fare con jamovi in modo visuale, aprendo, una per una, le linguette della barra del menu.

3.1 Variabili

Nella finestra di apertura di jamovi, che è riprodotta a pagina 3, abbiamo già, nella finestra di lavoro sulla sinistra, una sorta di foglio elettronico destinato all'inserimento di dati con predisposte tre colonne, destinate a ricevere i dati di altrettante variabili, denominate A, B e C.


Rammento che, in statistica, una variabile è praticamente sempre una serie di dati e viene ospitata da jamovi, come avviene in altri software per elaborazioni statistiche e nei fogli di calcolo, in una colonna di un foglio elettronico.

Per default, le tre variabili presenti nel foglio in apertura del programma sono inizializzate al tipo di misura *Nominale* e al tipo di dato *Intero*. Si tratta di una scelta salomonica che usa un tipo di dato elaborabile (il numero intero) lasciando aperta la strada che lo può utilizzare come indicatore qualitativo (misura nominale).

Per analisi semplici ci possiamo accontentare, tanto più che, se inseriamo nella colonna della variabile che ci viene proposta per default una etichetta di testo anziché un numero intero, l'inizializzazione della variabile si adatta automaticamente al tipo di misura *Nominale* e al tipo di dato *Testo* e, se inseriamo nella colonna della variabile che ci viene proposta per default un numero con cifre decimali, l'inizializzazione della variabile si adatta automaticamente al tipo di misura *Continua* e al tipo di dato *Decimale*.

Tutte queste cose le possiamo vedere con doppio click sulla casella contenente l'intestazione della colonna del foglio elettronico.

Dal momento, poi, che, sempre agendo sul foglio elettronico che ci viene proposto in apertura del programma cliccando sull'intestazione bianca di colonne non ancora assegnate a variabili, possiamo aggiungere nuove variabili, anche calcolate e trasformate, potremmo anche fare a meno di ciò che ci viene proposto cliccando sulla linguetta di menu *VARIABILI*, azione attraverso la quale ci viene proposta questa barra di strumenti



Il ricorso a questo strumento serve a creare un data set con tipi di misura e tipi di dato precostituiti e non assoggettabili ad adattamenti automatici in relazione al dato inserito.

Come dire che, per analisi serie e complicate, è sempre bene avvalersi di questo strumento per intelaiare il data set.

Il primo pulsante sulla sinistra (icona con la scritta *MODIFICA*) serve per annullare o ripristinare modifiche effettuate prima.

L'altro pulsante, il secondo da sinistra (icona pure con la scritta *MODIFICA*), ci dà modo di scrivere una descrizione per le variabili e, con riferimento alla variabile selezionata, assegnarle un nome e fissarne tipo di misura (potendo scegliere tra *Nominale*, *Ordinale* e *Continua*) e il tipo del dato (potendo scegliere tra *Intero*, *Decimale* e *Testo*).

Procedendo verso destra abbiamo il pulsante corrispondente all'icona con la scritta *CALCOLA*, che ci dà modo di rendere variabile calcolata quella selezionata inserendo la formula per effettuare il calcolo coinvolgendo altre variabili, come fossimo in un foglio di calcolo.

A seguire il pulsante corrispondente all'icona con la scritta *TRASFORMA*, che ci dà modo di creare una nuova variabile applicando una formula di trasformazione ai dati della variabile selezionata.

Poi tasti per aggiungere nuove variabili o eliminare variabili.

Infine un tasto per filtrare i dati, corrispondente all'icona con l'imbuto e la scritta *FILTRO*, che ci dà modo di eliminare dalla colonna della variabile selezionata dati corrispondenti ad una determinata condizione, creando una variabile filtro che si aggiunge a quelle presenti nel dataset. Eliminando questa variabile filtro tutto torna come prima.

3.2 Dati

Cliccando sulla seconda linguetta da sinistra della barra del menu, nominata DATI, mostriamo il dataset in un foglio elettronico su cui possiamo intervenire attraverso le azioni sottese ai pulsanti con le icone che compaiono in questa barra di strumenti



Alcune azioni sono simili a quelle già viste prima per la creazione delle variabili, con la differenza che qui, oltre a creare, modificare o trasformare una variabile agendo su un elenco di variabili lo facciamo agendo sul foglio elettronico che le contiene, potendo anche inserire le serie che compongono le variabili stesse.

Di nuovo troviamo il primo raggruppamento di icone che sottendono azioni di taglia, copia e incolla, la possibilità di aggiungere o eliminare oltre che colonne anche righe e la possibilità di pesare le componenti di una variabile.

A quest'ultimo scopo dobbiamo creare una variabile contenente i pesi da attribuire a varie righe di una variabile e poi, cliccato sul pulsante contrassegnato dall'icona con la scritta PESI, indicare la variabile cui attribuire questi pesi. In questo modo le analisi che coinvolgono quella variabile sono condotte attribuendo alla variabile stessa i pesi indicati. Eliminando la variabile contenente i pesi tutto torna come prima.


3.3 Analisi

La terza linguetta della barra del menu, nominata ANALISI, apre finalmente la strada al core del nostro software e cliccando su di essa ci ritroviamo questa barra di strumenti



* * *

Il primo strumento, ESPLORAZIONE, presenta questo menu



Scegliendo la voce DESCRITTIVE apriamo una finestra nella quale dobbiamo indicare la colonna/variabile o le colonne/variabili di cui indicare le statistiche. Se indichiamo più colonne le statistiche vengono indicate, colonna per colonna affiancate.

Per default vengono indicate media, mediana, deviazione standard, minimo e massimo. Se vogliamo altre statistiche possiamo sceglierle aprendo il sotto-menu STATISTICHE nella stessa finestra.

Sempre in questa finestra abbiamo un sottomenu GRAFICI che lasciamo agli esperti.

Per i meno esperti, a proposito di grafici, può essere utile scegliere una delle due voci di menu SCATTER PLOT e PARETO PLOT.

Nel primo caso, dovendo indicare dati numerici sia sull'asse delle ascisse sia sull'asse delle ordinate nella finestra che si apre, otteniamo un grafico con punti che segnano le corrispondenze tra le varie ascisse e le varie ordinate.

Aprendo la voce GENERAL OPTIONS in questa finestra possiamo scegliere se indicare l'interpolante (qui chiamata REGRESSION LINE), in modalità LINEAR o SMOOTH.

Sempre in questa finestra abbiamo le voci PLOT & AXIS TITLES, AXIS e LEGEND aprendo le quali abbiamo modo di intervenire per completare il grafico con titoli e legende.

Nel secondo caso, dovendo indicare dati di misura nominale o ordinale sull'asse delle ascisse e dati numerici sull'asse delle ordinate nella finestra che si apre, otteniamo una sorta di grafico a barre, detto di Pareto, arricchito della curva delle percentuali cumulative.

* * *

A seguire abbiamo lo strumento TEST T, che presenta questo menu



La prima scelta, TEST T A CAMPIONI INDIPENDENTI, serve per valutare la significatività della differenza tra medie campionarie osservate su campioni separati e indipendenti.

Come a dire verificare se il peso medio di pomodori coltivati in un'area concimata è significativamente diverso dal peso medio di pomodori coltivati in un'area non concimata.

In questo caso i dati delle osservazioni campionarie vanno inseriti in una sola colonna del foglio elettronico dei dati, come si trattasse di una sola variabile, affiancata da altra colonna in cui inserire un indicatore di raggruppamento per indicare il campione di appartenenza del dato inserito nella prima colonna (l'indicatore può essere il numero 1 per un campione e 2 per l'altro).

Nella finestra in cui inserire i dati, si inserisce il nome della prima colonna, l'unica contenente i dati delle rilevazioni campionarie, nella zona VARIABILI DIPENDENTI e il nome della colonna con gli indicatori di raggruppamento nella zona VARIABILE DI RAGGRUPPAMENTO.

La seconda scelta, TEST T A CAMPIONI ACCOPPIATI, serve per valutare la significatività della differenza tra medie campionarie su osservazioni fatte sullo stesso campione in momenti separati. Come a dire verificare se la media delle misurazioni della pressione sanguigna a diverse ore effettuate prima di un trattamento è diversa da quella delle misurazioni effettuate alle stesse ore dopo un trattamento, sullo stesso paziente.

In questo caso abbiamo i dati delle misurazioni in due diverse colonne/variabili del foglio elettronico che contiene i dati e indichiamo i loro nomi nella zona VARIABILI ASSOCIATE nella finestra in cui inserire i dati.

La terza scelta, TEST T A CAMPIONE SINGOLO, serve per valutare la significatività della differenza tra una media campionaria e un certo valore.

Come a dire verificare se la media delle misurazioni del peso del contenuto di alcuni flaconi è significativamente diversa da quella indicata sull'etichetta dei flaconi.

In questo caso abbiamo una sola variabile da indicare nella zona VARIABILI DIPENDENTI della finestra in cui inserire i dati, quella che contiene le misurazioni campionarie, e dobbiamo inserire il valore con cui instaurare il confronto nella zona IPOTESI della stessa finestra, nella finestrella VALORE DEL TEST.

Nelle finestre per l'inserimento dei dati gli statistici professionisti trovano una miriade di possibilità di arricchire questi tipi di analisi basate sul test di Student.

* * *

Il successivo strumento è etichettato ANOVA, che sta per ANalysis Of VAriance. Nonostante il suo nome esso, come il test t che abbiamo visto prima, serve per valutare la significatività della differenza tra medie.

Questa apparente stranezza è dovuta al fatto che utilizza un adattamento del test F di Fisher-Snedecor, originariamente dedicato all'analisi della varianza.

Nella versione originale il test F si basa sul rapporto tra due varianze campionarie per verificare se esse possono dirsi accidentalmente o significativamente diverse.

Nell'adattamento utilizzato da ANOVA il test F si basa invece sul rapporto tra varianza tra gruppi e varianza entro i gruppi, cioè rapportando il quanto le medie di più gruppi sono lontane tra loro (tra gruppi) e il quanto i punti interni ai gruppi sono sparsi attorno alla loro media (entro i gruppi). Per questa via, basandosi totalmente su analisi di varianze, si arriva a valutare la significatività o meno della differenza tra medie.


ANOVA nasce per superare due limiti dell'analisi attraverso il test t.

Il primo dato dal fatto che esso è applicabile solo a due gruppi per volta.

Il secondo, dato dal fatto che per essere certi dell'attendibilità dei risultati raggiunti applicando il test t dovremmo prima verificare che le varianze dei gruppi non siano significativamente diverse.

Con ANOVA possiamo confrontare più di due gruppi contemporaneamente, superando così il primo limite, e abbiamo a disposizione più strumenti di analisi, tra cui quello per superare anche il secondo limite.

Il suo menu si presenta così



L'applicazione normale risponde alla voce ANOVA.

La voce ANOVA A UNA VIA SERVE quando si vuole verificare se le medie di tre o più gruppi sono significativamente diverse in funzione di un solo fattore, per esempio per valutare l'effetto di diversi fertilizzanti sulla crescita di una pianta.


La voce ANOVA A MISURE RIPETUTE serve quando gli stessi soggetti vengono misurati più volte, come prima, durante e dopo un terapia sullo stesso paziente.

ANCOVA sta per Analisi della Covarianza, e serve per confrontare le medie dei gruppi aggiustate per una variabile continua.

MANCOVA sta per Analisi Multivariata della Covarianza ed è l'evoluzione multivariante di ANCOVA.

* * *

Proseguendo verso destra troviamo lo strumento REGRESSIONE, che presenta questo menu



La voce MATRICE DI CORRELAZIONE ci dà modo di ottenere il coefficiente di correlazione tra due variabili, nel caso di più variabili a coppie in una tabella a matrice ed anche di ottenere piccoli grafici che visualizzano l'interpolante. Gli indicatori che possiamo ottenere sono quelli di Pearson, di Spearman e di Kendall.

La voce CORRELAZIONE PARZIALE ci consente di ottenere il coefficiente di correlazione tra due variabili eliminando il possibile effetto di un'altra o di altre variabili, dette variabili di controllo. Per esempio per misurare la correlazione tra l'altezza (X) e la circonferenza del torace (Y) di un gruppo di persone eliminando l'influenza del peso (Z) che verosimilmente è correlato sia all'altezza che al torace.


Attraverso la voce REGRESSIONE LINEARE otteniamo gli elementi per determinare l'equazione della retta di regressione (intercetta e coefficienti) che sintetizza la relazione funzionale esistente tra una variabile dipendente e una o più variabili indipendenti (regressione multipla).

Le variabili indipendenti possono essere di tipo numerico, ed è questo il caso tipico, e jamovi le definisce Covariate ma possono anche essere di tipo nominale, nel qual caso sono definite Fattori. Attraverso una variabile di pesatura possiamo attribuire pesi diversi alle variabili indipendenti.

Abbiamo poi accesso a tre varianti di REGRESSIONE LOGISTICA, a 2 RISULTATI se la variabile dipendente ha due sole classi (sì/no, sano/malato), a N RISULTATI, utilizzata quando la variabile dipendente ha più di due classi non ordinate (auto/treno/bici/bus), e a RISULTATI ORDINALI quando la variabile dipendente ha più di due classi ordinate (insufficiente/sufficiente/buono/ottimo).

* * *

Abbiamo poi lo strumento FREQUENZE, che presenta questo menu



I TEST PER LA PROPORZIONE IN UN CAMPIONE servono a verificare se la proporzione o la distribuzione di frequenze osservate in un campione sono diverse da una proporzione teorica o attesa o da una distribuzione teorica o attesa.

Se la variabile ha solo due categorie (si/no, promosso/bocciato) e basta confrontare la proporzione tra le due si ricorre al test binomiale a 2 RISULTATI.

Se la variabile ha più di due categorie diventa una distribuzione vera e propria e si ricorre al test a N RISULTATI, altrimenti noto come test del χ^2 della bontà di adattamento.

Una tabella di contingenza (o a doppia entrata) è uno strumento statistico utilizzato per mettere in relazione due o più variabili categoriali, organizzando i dati in righe e colonne per mostrare le frequenze congiunte.

L'analisi delle tabelle di contingenza (tabelle a doppia entrata) in jamovi si effettua nel modulo TABELLE DI CONTINGENZA che ci offre l'alternativa tra CAMPIONI INDIPENDENTI, applicabile nel caso ogni soggetto compaia una sola volta e i gruppi siano diversi tra loro, e CAMPIONI ACCOPPIATI, applicabile se i dati provengono dagli stessi soggetti misurati più volte.

* * *

Infine abbiamo lo strumento FATTORE, che presenta questo menu



L'ANALISI DI AFFIDABILITÀ serve a verificare quanto una scala misura in modo coerente e stabile ciò che vuole misurare, cioè controlla se gli item di una scala “vanno nella stessa direzione” e producono risultati consistenti.

Si usa per capire se le domande della scala sono coerenti tra loro, se ogni item contribuisce davvero alla misura del costrutto e se il punteggio totale della scala è affidabile.

Se una scala è poco affidabile, i risultati possono dipendere più dal caso o da errori di misura che dal fenomeno studiato.

L'ANALISI DELLE COMPONENTI PRINCIPALI è orientata alla riduzione dei dati con l'obiettivo di riassumere molti dati in poche componenti, creando nuove variabili come combinazione delle variabili originali.

L'ANALISI FATTORIALE ESPLORATIVA si applica quando non si sa quanti fattori esistono e lo si vuole scoprire dai dati,

L'ANALISI FATTORIALE CONFERMATIVA serve per verificare i risultati dell'analisi fattoriale esplorativa.

* * *


Avendo caricato il relativo modulo secondo quanto abbiamo visto nel Capitolo 2, abbiamo anche a disposizione l'Editor R, in due modalità:

. RJ EDITOR, semplice e diretto, permette di scrivere ed eseguire codice R puro; i risultati vengono mostrati come output testuale o grafico. Serve per analisi personalizzate veloci a chi conosce già R e vuole usare jamovi solo come ambiente dati o per testare codice o fare analisi non presenti nei moduli standard.

. RJ EDITOR +, più avanzato e orientato allo sviluppo di analisi integrate. Serve per creare analisi riutilizzabili o sviluppare moduli o procedure personalizzate.

3.4 Grafici

La quarta linguetta della barra del menu, nominata GRAFICI ci offre la possibilità di tracciare alcune tipologie di grafico e cliccando su di essa ci ritroviamo questa barra di strumenti




Troviamo tre tipi di grafico adatti alla visualizzazione di frequenze e distribuzioni di frequenze, BAR PLOT, BOX PLOT e HISTOGRAM e due tipi di grafico per visualizzare la relazione intercorrente tra due variabili numeriche, SCATTER PLOT e LINE PLOT.

Cliccando su MORE troviamo la possibilità di costruire un grafico PARETO PLOT. Si tratta di un grafico a barre che si presta a visualizzare grandezze (asse Y) riferite a variabili qualitative (asse X) con la curva rappresentante la percentuale cumulativa.

3.5 Modifica

Abbiamo infine la linguetta MODIFICA, cliccando sulla quale apriamo questa barra di strumenti



Questa volta si tratta di strumenti che non hanno nulla a che vedere con la statistica, ma servono a formattare un testo, come fossero da utilizzare in un editor di testo.

E' con questi strumenti che possiamo intervenire nella finestra in cui abbiamo i risultati delle elaborazioni per inserire annotazioni a chiarimento delle elaborazioni stesse.

Parte IV

Gretl

GRETl nasce ad opera di Allin Cottrell, della Wake Forest University, grazie ad un precedente lavoro di supporto didattico di Ramachandra (Ramu) Ramanathan, un professore della University of California che associò ad una grande cultura economica una vera e propria passione per la matematica, la statistica e l'informatica.

Il primo rilascio è del 31 gennaio 2000 e da allora il team di sviluppo si è molto allargato, rimanendo sempre capitanato da Allin Cottrell, ben spalleggiato dal nostro connazionale Riccardo “Jack” Lucchetti dell'Università Politecnica delle Marche di Ancona.

Software libero a tutti gli effetti, nato su Linux è rilasciato sotto licenza GNU, come il suo stesso nome suggerisce. GRETl è infatti l'acronimo di GNU Regression, Econometrics and Time-series Library.

Inizialmente concentrato sull'analisi delle serie temporali oggi rappresenta quanto di meglio disponibile per la statistica economica e l'econometria, insieme al blasonato e costoso EViews.

Mentre quest'ultimo è disponibile solo per il sistema operativo Windows, GRETl può essere utilizzato non solo su Windows ma anche su Linux e Mac.

Al centro di tutto l'apparato di strumenti di analisi troviamo la regressione, applicata come autoregressione nell'elaborazione delle serie storiche o come modello lineare ad interpretare relazioni tra variabili, quella che quando parliamo di data science troviamo alla base del così detto machine learning.

In econometria occorrono particolari accorgimenti, e GRETl ce ne offre tanti, per evitare che i modelli regressivi, applicati acriticamente, portino a risultati erranei a causa di problemi tipicamente ricollegabili alla natura di certi dati che ricorrono in campo economico: problemi di eteroschedasticità (i dati di una stessa variabile «risparmio» hanno certamente varianze diverse se la variabile è riferita a popolazione poco abbiente o a popolazione ricca), di multicollinearità (variabili come «reddito» e «risparmio» sono chiaramente correlate tra loro e, se entrano nello stesso modello, occorre evitare che ciò porti distorsioni), ecc.

Mai come in altre discipline matematico-statistiche troviamo un'attenzione agli errori di valutazione ed agli indicatori di attendibilità che troviamo in econometria e GRETl ci aiuta molto in questo.

Nel presente manualetto a portata di dilettante troviamo una semplice introduzione allo strumento, giusto per vedere come funziona e come potersene servire per le cose più banali.

Per gli approfondimenti occorre probabilmente essere un tantino meno dilettanti e, oltre, ovviamente, ad avere una preparazione in scienza economica, bisogna conoscere l'inglese. Esiste infatti parecchia documentazione su GRETl in rete e di particolare pregio è quella che ci propone il software che installiamo.

Purtroppo l'ultima guida pubblicata in lingua italiana, a cura di Cristian Rigamonti, è del 2008 e riguarda la versione 1.7.1 di GRETl, rilasciata il 26 dicembre 2007, quando quella in uso nel momento in cui scrivo (ottobre 2026) è la 2025a, rilasciata il 21 marzo 2025.

E' a quest'ultima versione che qui mi riferisco.

1 Installazione

GRETl si trova all'indirizzo <http://gretl.sourceforge.net/>.

Nella home page troviamo un'ampia descrizione del software, che possiamo scorrere anche avvalendoci dell'indice sulla sinistra.

Anche per l'installazione operiamo partendo dalla home page.

Sistema Linux

Nato su Linux, GRETl non fa nulla per essere di facile installazione su Linux e ai poveri linuxiani, da sempre considerati smanettoni, per essere installato offre il codice sorgente in un bell'archivio tar.xz che va compilato: l'ultimo rilasciato si chiama `gretl-2026b.tar.xz` e vi si accede cliccando sulla voce DOWNLOAD nell'indice della home page.

In teoria l'installazione per compilazione dovrebbe avvenire con la solita serie di comandi `./configure`, `make`, `make check` e `make install`, ma subito dopo il primo comando si apre una serie di complicazioni con le dipendenze e non ci si distraica più. In genere si finisce col dire «ma chi me lo fa fare!».

Fortunatamente mi pare che GRETl sia presente praticamente in tutti i repository delle varie distro e, in questi casi, è installabile in un soffio attraverso i gestori di programmi.

Così facendo, tuttavia, non potremo mai avere installata l'ultima versione del software, visto che i suoi aggiornamenti sono mediamente più fitti rispetto alle cadenze con cui escono le varie distribuzioni Linux.

Sistema Windows

Nell'indice sulla sinistra della home page clicchiamo su GRETl FOR WINDOWS e apriamo una pagina dalla quale scarichiamo gli installer potendo scegliere tra sistema a 64 bit o a 32 bit.

Il file da scaricare è quello relativo alla latest release, lasciando perdere i current snapshots.

Sistema Mac OS

Nell'indice sulla sinistra della home page clicchiamo su GRETl ON MACOS e apriamo una pagina in cui siamo guidati a scaricare l'installer adatto alla versione del nostro MacOS.

* * *

Con l'installazione, nella nostra home, viene creata una directory denominata `gretl`, destinata ad accogliere tutti i lavori che facciamo con GRETl.

2 Come funziona

Per lanciare GRETl abbiamo a disposizione due comandi:

```
gretl,  
gretlcli.
```

Il primo, che corrisponde al lanciatore con icona che si è creato quando abbiamo installato il software, apre GRETl con interfaccia grafica (GUI).

Il secondo apre GRETl a riga di comando su terminale, quello che in Linux e Mac si chiama Terminale e su Windows si chiama Prompt dei comandi.


E' possibile aprire GRETl a riga di comando utilizzando l'interfaccia grafica e, in questo caso, realizziamo una comoda integrazione tra ciò che facciamo a terminale e ciò che facciamo con l'interfaccia grafica.

Quando lavoriamo con interfaccia grafica abbiamo a disposizione mouse e menu, quando lavoriamo a riga di comando abbiamo a disposizione comandi da scrivere con la tastiera.

I comandi di GRETl formano un vero e proprio linguaggio di scripting, chiamato HANSL, acronimo ricorsivo di Hansl's A Neat Scripting Language.

Ma andiamo per ordine.

L'interfaccia grafica di GRETl è questa




In alto abbiamo una barra dei menu, nella figura non tutti attivati in quanto, come evidenziato nella barra sottostante, nessun dato è stato ancora caricato.

Se apriamo la voce AIUTO troviamo un nutrito elenco di help e manuali su tutto ciò che si può fare con la versione di GRETL su cui siamo, compresa una guida completa all'uso di GRETL, in lingua inglese.

Nella barra inferiore abbiamo una serie di icone. Passando il mouse su ciascuna di esse vediamo a cosa servono.

Cliccando sulla terza da sinistra apriamo GRETL a riga di comando



Senza ancora aver caricato dati abbiamo a disposizione alcuni strumenti, accessibili, appunto, da menu STRUMENTI, tra i quali una simpatica serie dedicata ai test statistici più famosi con possibilità di vederne distribuzione, valori critici e p-value.

Anche qui troviamo la possibilità di aprire il terminale per lavorare a riga di comando, di aprire una finestra per lavorare direttamente con Gnuplot o per lavorare con GNU R.

Gnuplot è il software libero di cui GRETL si avvale per creare grafici. Con gli installatori di GRETL per Windows e Mac viene automaticamente installato anche questo software, mentre su Linux, dove spesso fa parte della dotazione di base del sistema operativo, deve eventualmente essere installato a parte.

GNU R è il potente software libero per elaborazioni statistiche che potremmo utilizzare a potenziamento di ciò che possiamo fare con GRETL. In ogni caso deve essere installato a parte e, per funzionare, deve avere a disposizione dati.

3 Caricamento dei dati

I dati con cui comunemente abbiamo a che fare in econometria possono essere strutturati in tre modi diversi.

Possiamo avere dati sezionali (cross section) quando siamo in presenza della rappresentazione di una o più variabili senza riguardo alle variazioni nel tempo delle osservazioni, esattamente come in un'istantanea.

Ad esempio reddito e consumo delle famiglie italiane per provincia nel 2020.

Abbiamo serie storiche quando siamo in presenza di una o più variabili ordinate rispetto al tempo.

Ad esempio reddito e consumo delle famiglie italiane dal 2001 al 2020.

Possiamo, infine, avere dati longitudinali (panel) quando siamo in presenza dell'osservazione di più variabili, ciascuna in una serie di periodi di tempo.

Ad esempio reddito e consumo delle famiglie italiane per provincia dal 2001 al 2020.

GRETl è attrezzato per trattare nel modo migliore queste strutture di dati, fornendoci anche diversi modi di caricarle per essere elaborate.

3.1 Immissione diretta

Da menu FILE ► NUOVO DATASET apriamo questa finestrella



nella quale vediamo che ci viene innanzi tutto chiesto di indicare, con riferimento alle tre possibilità viste prima, quale tipo di dataset vogliamo creare e quanti dati debba contenere (n come numero di righe di una tabella nel caso di dati sezionali a cross section, T come numero di periodi di tempo nel caso di serie storiche, entrambi questi elementi nel caso di dati longitudinali a panel).

In questo momento non interessa il numero delle variabili, che sarà gestito nel seguito.

Una volta fatta la scelta e cliccato su Avanti siamo guidati per l'inserimento dei valori della prima variabile lavorando in una sorta di foglio elettronico che ci viene aperto in modo commisurato al numero e al tipo di dati da inserire.

Cliccando sull'icona con il simbolo + di questa sorta di foglio elettronico possiamo inserire i dati per quante altre variabili vogliamo.

3.2 Importazione

I dati da elaborare possono essere importati da altri dataset o da file di lavoro di altri software econometrici (file .xpt di SAS e file .wf1 di EViews).

Gli altri dataset possono essere file .csv (dove i separatori ammessi sono la virgola, lo spazio, la tabulazione e il punto e virgola), file Excel (.xls) o file di foglio di calcolo .ods (prodotti con Open Office e Libre Office).

La prima riga del dataset importato deve contenere i nomi delle variabili (ciascuno identificato con un massimo di 31 caratteri).

Se la prima colonna contiene identificativi di osservazione o date deve avere come intestazione obs oppure date.

Le date possono essere indicate in anni, trimestri o mesi.
 L'anno si indica con quattro cifre.
 Il trimestre si indica con le quattro cifre dell'anno, seguite da un punto (.) o da due punti (:) e da un numero di una cifra (1 2 3 o 4).
 Il mese si indica con le quattro cifre dell'anno seguite da un punto (.) o da due punti (:) e da un numero di due cifre (01 02 03 ecc. fino a 12).
 I file da importare è bene siano disponibili nella cartella gret1 della nostra home.
 L'importazione avviene scegliendo da menu FILE ▷ APRI DATI ▷ FILE UTENTE...
 Da dataset esterni possiamo importare solo dati sezionali (cross section) o serie storiche.
 Il menu FILE ▷ APRI DATI ci offre anche l'alternativa ▷ FILE DI ESEMPIO... attraverso la quale possiamo caricare dataset che GRETL mette a disposizione a scopo didattico. Tra questi vi sono anche numerosi panel.
 L'importazione di dati può essere fatta da terminale con il comando open seguito dal nome del file che contiene i dati.

4 Accuratezza numerica

GRETL, nei calcoli, tratta i dati numerici come numeri a virgola mobile in doppia precisione (64 bit).

Quando li scrive utilizza otto cifre, virgola compresa se si tratta di numeri decimali.

Gli interi con più di otto cifre vengono scritti in notazione scientifica.

Se il numero è memorizzato in una variabile, con il comando `printf` possiamo scriverlo utilizzando la direttiva di formattazione `%.f` in cui, prima del punto si indicano le cifre per la parte intera e dopo il punto si indicano le cifre per la parte decimale.

In questo modo possiamo scrivere quante cifre vogliamo ma quelle precise saranno 16, corrispondenti a quelle della doppia precisione.

Esempi:

Se la variabile `x` contiene il valore $1/3$, questo viene normalmente espresso come 0,333333 (otto cifre, virgola compresa).

Con il comando

```
printf "%1.18f", x
```

il contenuto della variabile `x` viene espresso come 0,333333333333333370, cioè con le 18 cifre decimali richieste, di cui tuttavia solo le prime 16 precise.

Così, posto che il valore di 345^8 è 200702490011187890625, calcolato in GRETL e inserito nella variabile `y` viene normalmente espresso come 2,00702e+20.

Con il comando

```
printf "%21.0f", y
```

il contenuto della variabile `y` viene espresso come 200702490011187937280, cioè le 21 cifre richieste, di cui tuttavia solo le prime 16 precise, con la sedicesima arrotondata.

5 Comandi e funzioni

Per le elaborazioni GRETL si avvale di una nutrita serie di comandi e di funzioni, richiamabili con i loro nomi se lavoriamo a riga di comando oppure attraverso voci di menu se lavoriamo con interfaccia grafica.

L'elenco dei comandi di GRETL è disponibile da menu AIUTO ▷ GUIDA COMANDI in GRETL con GUI oppure scrivendo il comando `help` in GRETL a riga di comando.

Nel primo caso cliccando sul nome di un comando ne otteniamo una esauriente descrizione in italiano con esempi.

Lo stesso avviene nel secondo caso scrivendo a terminale il comando `help` seguito dal nome del comando di cui vogliamo avere la descrizione.

Allo stesso modo l'elenco delle funzioni è disponibile da menu AIUTO ▸ GUIDA FUNZIONI in GRETL con GUI oppure scrivendo il comando `help functions` in GRETL a riga di comando.

Anche la descrizione in lingua italiana con esempi si ottiene cliccando sul nome della funzione se lavoriamo con GUI o attraverso il comando `help` seguito dal nome della funzione se lavoriamo a riga di comando.

Lavorando a riga di comando, con i comandi, ma soprattutto con le funzioni, possiamo compiere praticamente qualsiasi tipo di calcolo al di là di quelle che sono le elaborazioni statistiche ed econometriche cui abbiamo accesso lavorando con interfaccia grafica.

Inoltre l'insieme dei comandi e delle funzioni forma il linguaggio di scripting di GRETL, denominato HANSL.

6 Linguaggio HANSL

In GRETL con GUI, da menu AIUTO ▸ INTRODUZIONE AD HANSL, accediamo ad una guida, in lingua inglese, che mette in condizione chiunque abbia una minima infarinatura di programmazione di programmare GRETL utilizzando HANSL.

Per muovere i primi passi, e forse per fare qualche cosa in più, propongo una miniguia in questo paragrafo.

6.1 Interattività e script

Possiamo utilizzare il linguaggio in maniera interattiva lavorando nel terminale di GRETL oppure per predisporre script che hanno il vantaggio di poter essere conservati e riutilizzati quando serve.

Nel primo caso scriviamo le istruzioni a terminale rispettando la sintassi del linguaggio e alla pressione del tasto INVIO le vediamo eseguite.


Nel secondo caso scriviamo le istruzioni in un file di testo che memorizziamo con estensione `.inp`, che può essere richiamato con il comando nel generico terminale del sistema operativo

```
gretlcli -b <nome_file>.inp
```

per essere eseguito.

Il file di testo può essere convenientemente scritto utilizzando l'editor di GRETL, che si apre cliccando sulla seconda icona (quella con rappresentata una matita) nella barra inferiore della GUI di GRETL.

L'editor si presenta così



Passando il mouse sulle icone della barra degli strumenti otteniamo la descrizione di questi. Di particolare interesse il sesto da sinistra, cliccando sul quale eseguiamo lo script.

6.2 Tipi e variabili

Come in tutti i linguaggi di programmazione possiamo avvalerci di variabili, posizioni di memoria in cui teniamo a disposizione dati soggetti ad elaborazione secondo le istruzioni contenute nello script.

Il linguaggio HANSL è un linguaggio tipizzato, per cui si richiede che le variabili che prevediamo di utilizzare siano dedicate ad uno ed uno solo tipo di dato.

Le variabili possono essere create anche al momento in cui servono, non come avviene in altri linguaggi di programmazione strutturati nei quali si richiede siano preventivamente dichiarate.

L'istruzione per creare una variabile è semplicissima ed è composta dall'indicazione del tipo di dato che essa deve contenere e dal nome con cui identificarla

<tipo> <nome_variabile>

L'assegnazione di un dato alla variabile avviene con l'operatore di assegnamento = secondo la sintassi

<nome_variabile> = <valore>

dove <valore> deve essere del tipo indicato al momento della creazione della variabile vuota.

Al momento della creazione della variabile possiamo inizializzarla, assegnandole subito un valore, con la sintassi

<tipo> <nome_variabile> = <valore>

In questo caso possiamo omettere l'indicazione del tipo in quanto esso viene automaticamente dedotto ed assegnato in funzione del valore inserito, per cui possiamo creare ed inizializzare una variabile con l'istruzione abbreviata

<nome_variabile> = <valore>

6.2.1 Tipi base

I tipi base sono tre.

Stringa

Una stringa (string) è una successione di caratteri contenuta tra doppi apici.

Se scriviamo nel terminale di GRETL l'istruzione

S = "Vittorio"

otteniamo in risposta il messaggio

Generata la stringa S

che, in realtà, è la conferma della creazione di una variabile, chiamata S, destinata a contenere un dato di tipo string, dato che è attualmente rappresentato dal nome Vittorio.

Scalare

Uno scalare (scalar) è un dato numerico singolo.

Se scriviamo nel terminale di GRETL l'istruzione

X = 2.75

otteniamo in risposta il messaggio

Generato lo scalare X = 2,75

Matrice

La matrice (matrix) è un insieme ordinato di dati numerici.

Può essere ad una sola dimensione, nel qual caso si dovrebbe parlare più propriamente di vettore, o a due dimensioni.

L'insieme ordinato di numeri si ottiene elencando questi tra parentesi graffe e separando con una virgola (,) i numeri appartenenti alla stessa riga e con un punto e virgola (;) le diverse righe.

Sicché una sola successione di numeri separati da virgola genera un vettore riga e una sola successione di numeri separati da punto e virgola genera un vettore colonna.

Nel caso della matrice vera e propria abbiamo l'indicazione di più vettori riga separati da punto e virgola. Affinché la matrice sia coerente occorre che il numero degli elementi di ciascuna riga sia sempre lo stesso. Nel caso il numero degli elementi di ciascuna riga sia pari al numero delle righe abbiamo una matrice quadrata.

$R = \{1, 2, 3\}$ inserisce nella variabile R, di tipo matrix, il vettore riga

```
1 2 3
```

$C = \{1; 2; 3\}$ inserisce nella variabile C, di tipo matrix, il vettore colonna

```
1  
2  
3
```

$M = \{1, 2, 3, 4; 5, 6, 7, 8\}$ inserisce nella variabile M, di tipo matrix, la matrice

```
1 2 3 4  
5 6 7 8
```

$MQ = \{1, 2, 3, 4, 5, 6; 7, 8, 9\}$ inserisce nella variabile MQ, di tipo matrix, la matrice quadrata

```
1 2 3  
4 5 6  
7 8 9
```

6.2.2 Tipi strutturati

Sono tipi contenitori in quanto sono delle aggregazioni di elementi di un certo tipo.

Array

L'array di GRET (array) può contenere zero o più elementi dello stesso tipo indicizzati con interi consecutivi a partire da 1.

Gli elementi assegnabili ad un array di GRET devono essere di tipo string, o di tipo matrix, o di tipo bundle (che vedremo subito) o di tipo list (che vedremo successivamente).

La creazione di un array che debba ospitare un certo numero di elementi di un certo tipo avviene con la sintassi

```
<tipo_plurale> <nome_array> = array(<numero>)
```

dove <tipo_plurale> è il tipo degli elementi che l'array potrà ospitare al plurale (strings per il tipo string, matrices per il tipo matrix, bundles per il tipo bundle e lists per il tipo list) e <numero> è il numero degli elementi che potranno essere inseriti nell'array.

Con l'istruzione

```
strings S = array(4)
```

viene creato l'array denominato S predisposto per contenere 4 elementi di tipo stringa.

L'inserimento degli elementi avviene per assegnazione alla posizione identificata dall'indice $S[2] = \text{"Giuseppe"}$

asigna la stringa "Giuseppe" come secondo elemento (indice 2) dell'array.

Ovviamente l'inserimento dell'elemento può avvenire anche richiamando la variabile che lo contiene.

Al momento della creazione dell'array possiamo inizializzarlo con la funzione defarray con questa sintassi

```
<nome_array> = defarray(<elemento>, <elemento>, ...)
```

Possiamo evitare di indicare il tipo in quanto esso viene desunto da quello degli elementi inseriti, che deve essere sempre quello.

Bundle

Detto anche array associativo, il bundle (`bundle`) può contenere elementi di qualsiasi tipo previsto da GRETL, anche in modo eterogeneo, ciascuno identificato da una stringa chiave.

Per chi conosce il linguaggio Python siamo praticamente in presenza di quello che là si chiama dizionario. Per chi conosce il linguaggio Perl siamo praticamente in presenza di quello che là si chiama hash.

La creazione di un bundle avviene per semplice dichiarazione, con la sintassi
`bundle <nome_bundle>`

L'inserimento degli elementi avviene per assegnazione ad un indice, con la sintassi
`<nome_bundle> . <indice> = <elemento>`.

Esempio:

Con

```
bundle B
```

creiamo il bundle B vuoto

Con

```
B.a = 12
```

vi inseriamo lo scalare 12 identificato dalla chiave "a"

Con

```
B.b = "Pippo"
```

vi inseriamo la stringa "Pippo" identificata dalla chiave "b"

Al momento della creazione dell'array possiamo inizializzarlo con la funzione `defbundle` con questa sintassi

```
<nome_bundle> = defbundle(<chiave>, <elemento>, <chiave>, <elemento>, ...)
```

6.2.3 Tipi legati al dataset

Se abbiamo caricato un dataset secondo quanto abbiamo visto nel Paragrafo 3 possiamo definire variabili derivanti da esso secondo due tipi.

Serie

La serie (`series`) è un tipo adatto a contenere diverse osservazioni di una stessa grandezza, diverse nello spazio o nel tempo, come il reddito per provincia o il reddito osservato a cadenza annuale in un decennio.

Praticamente si tratta dei dati numerici contenuti in una colonna del dataset, colonna che possiamo richiamare attraverso la stringa che ne costituisce etichetta.

Esempio:

Supponiamo di aver caricato un dataset contenente redditi e consumi in un triennio

	reddito	consumo
2015	198	135
2016	201	136
2017	212	138

Con l'istruzione

```
series R = reddito
```

creiamo la variabile R contenente la serie di valori 198 201 212.

Con l'istruzione

`C = consumo`

creiamo la variabile `C` contenente la serie di valori 135 136 138.

La dichiarazione del tipo può essere omessa in quanto GRETL capisce il tipo della variabile dal tipo del dato inserito.

Lista

La lista (`list`) è un array di numeri identificativi di un set di serie ordinate a partire dal numero 1.

La variabile di tipo lista si crea, questa volta obbligatoriamente dichiarandone il tipo, con la sintassi

`list <nome> = <identificativo_serie>`

dove `<identificativo_serie>` può essere indicato attraverso il nome di una variabile `series` precedentemente creata, il numero d'ordine, nel dataset, della colonna o delle colonne da includere nella lista (partendo dal numero 1 a sinistra) oppure la stringa identificativa, nel dataset, della colonna o delle colonne da includere nella lista. L'ordine con cui scriviamo gli identificativi di serie sarà rispettato nella lista e la posizione nella lista viene indicizzata a partire da 1.

Il contenuto della variabile lista si può richiamare con la sintassi

`<nome> [<indice>]`

Esempio:

Con riferimento al dataset del precedente esempio, con l'istruzione

`list L = 2 1`

creiamo la variabile di tipo `list` `L` contenente, nell'ordine, la serie relativa al consumo (la numero 2 del dataset) e la serie relativa al reddito (la numero 1 del dataset).

Allo stesso risultato saremmo pervenuti con l'istruzione

`list L = consumo reddito`

Con l'istruzione

`L[1]`

richiamiamo la prima serie inserita nella lista, cioè quella relativa al consumo.

6.3 Operatori

L'operatore è un simbolo che viene inserito tra due operandi per generare un risultato.

Gli operandi possono essere indicati al momento oppure richiamando variabili che li contengono.

L'espressione contenente operandi ed operatori va indicata in una istruzione di assegnazione se vogliamo inserire il risultato in una variabile oppure come argomento della funzione `eval` se vogliamo scrivere il risultato a terminale.

6.3.1 Operatori aritmetici

Sono previsti operatori aritmetici per ciascun tipo base degli operandi.

Operandi stringa

Il principale operatore per il tipo string è quello per la concatenazione ed è rappresentato dal simbolo della tilde (`~`)².

Esempi:

²Il simbolo della Tilde si ottiene con `AltGr+ì` sulla tastiera Linux, `Alt+5` o `Alt+N` sulla tastiera Mac o `Alt+126` del tastierino numerico sulla tastiera Windows.

```
NC = "Vittorio" ~ " " ~ "Albertoni"
crea la variabile string NC con assegnata la stringa "Vittorio Albertoni"
eval "Vittorio" ~ " " ~ "Albertoni"
scrive a terminale Vittorio Albertoni
```

Operandi scalari

Per gli scalari valgono i soliti operatori aritmetici che, nell'ordine di precedenza, sono

- ^ per l'elevamento a potenza
- * per la moltiplicazione
- / per la divisione
- % per il modulo (resto della divisione intera)
- + per la somma
- per la sottrazione

Operandi matrici

Per le matrici utilizziamo gli stessi operatori previsti per gli scalari, salvo l'operatore %.

Se l'elevamento a potenza, la moltiplicazione o la divisione si vogliono effettuare membro a membro occorre far precedere l'operatore ^, * o / da un punto (.).

Esempio:

```
eval {1,2;5,3} * {4,2;2,3} ritorna
      8      8
      26     19
eval {1,2;5,3} .* {4,2;2,3} ritorna
      4      4
      10     9
```

6.3.2 Operatori di confronto

Servono per confrontare entità di tipo scalare e restituiscono un valore booleano (1 = vero, 0 = falso).

- == uguale
- != non uguale
- < minore
- > maggiore
- <= minore o uguale
- >= maggiore o uguale

6.3.3 Operatori logici

Servono per la verifica di più condizioni.

- && AND logico
- || OR logico
- ! NOT logico

6.4 Interattività con l'utente

Per l'interattività con l'utente non sono previste, come in altri linguaggi, istruzioni per la richiesta di input guidato da tastiera.

Sono invece previste istruzioni per l'output sullo schermo a terminale.

eval

Abbiamo già introdotto nel precedente paragrafo l'istruzione `eval`. Essa serve per scrivere a terminale il risultato di una espressione nella quale intervengano operatori.

```
eval 5*3-12 scrive 33
eval 3^3 scrive 27
eval 5>6 scrive 0
```

print

Con questa istruzione possiamo scrivere a terminale il contenuto di una variabile o una stringa indicata al volo.

```
print "Ciao" scrive Ciao
print X scrive il contenuto della variabile X
```

printf

Con questa istruzione possiamo scrivere a terminale una frase composta con elementi eterogenei inserendo nel testo anche valori di variabili, magari nemmeno noti al momento della stesura dello script, attraverso l'uso di segnaposti.

I segnaposti utilizzati sono

`%s` per valori di tipo stringa,
`%g` per valori di tipo numerico.

Come abbiamo già visto nel Capitolo 4, possiamo anche utilizzare direttive di formattazione per formattare dati numerici con il segnaposto

`%. _f`

dove prima del punto si indicano eventualmente le posizioni in cui allineare la parte intera del numero e dopo il punto si indica il numero delle cifre decimali da indicare, arrotondando l'ultima.

Esempio:

Data la variabile `nome`, contenente la stringa "Luigi" e la variabile `Y`, che nel corso dello script assumerà il valore 72,65687,

```
printf "Bravo %s, hai vinto %.2f euro\n", nome, Y
scrive
Bravo Luigi, hai vinto 72,66 euro
```

6.5 Strutture di controllo

Sono comandi per condizionare l'esecuzione di certe istruzioni al verificarsi di determinate condizioni o per l'esecuzione ripetuta di certe istruzioni.

6.5.1 Esecuzione condizionale

Il costrutto più semplice per l'esecuzione condizionale è

```
if <condizione>
    <istruzioni>
endif
```

Se la condizione è vera vengono eseguite le <istruzioni> e poi si prosegue con il resto del programma. Se la condizione è falsa non vengono eseguite le <istruzioni> e si prosegue con il resto del programma.

Nel costrutto possiamo indicare istruzioni da eseguire nel caso la prima condizione non sia vera con la parola chiave `else`

```

if <condizione>
    <istruzioni>
else
    <istruzioni>
endif
    Possiamo infine gestire il verificarsi di più condizioni alternative con
if <condizione>
    <istruzioni>
elif <condizione>
    <istruzioni>
...
...
else
    <istruzioni>
endif

```

6.5.2 Ripetizione

Per eseguire più volte le stesse istruzioni abbiamo la parola chiave `loop` con la seguente sintassi

```

loop <espressione_di_controllo>
    <istruzioni>
endloop

```

L'espressione di controllo più comune è quella che indica il numero di volte che devono essere eseguite le istruzioni con un intero

```

loop 5
print "Ciao"
endloop

```

scrive cinque volte la parola `Ciao`.

Altre espressioni di controllo utilizzano le parole chiave `while`, `for`, `foreach` e per queste rimando al manuale.

6.6 Creazione di funzioni

Nonostante GRETl offra una nutrita serie di funzioni, al punto che si fatica a dire che cosa manchi, offre anche all'utente la possibilità di creare lui stesso funzioni che vadano ad arricchire la raccolta.

La creazione di una funzione avviene con la seguente sintassi

```

function <tipo> <nome> (<tipo> <parametro>, ...)
    <istruzioni>
end function
    dove

```

`<tipo>` è il tipo del valore restituito dalla funzione ed è uno di quelli visti nel paragrafo 6.2,

`<nome>` è il nome identificativo della funzione, che serve per richiamarla,

`<parametri>` sono i dati da indicare alla funzione affinché essa possa produrre il risultato richiesto, `<istruzioni>` rappresentano ciò che deve fare la funzione per produrre il risultato. Alla fine delle istruzioni occorre indicare quale sia il risultato da restituire con la parola chiave `return`.

La funzione creata viene richiamata scrivendone il nome e, tra parentesi tonde, il valore dei parametri.

Possiamo salvare in un file con estensione `.inp` il testo della creazione della funzione e ogni volta che ci serve di utilizzare la funzione importarla, prima di richiamarla, con

```

include <nome_file>.inp

```

Esempi:

Poniamo, più per semplicità di esempio che per necessità, che ci sia comodo disporre di una funzione per raddoppiare un numero.

La possiamo produrre in questo modo:

```
function scalar raddoppia (scalar n)
doppio = n * 2
return doppio
end function
```

o, più semplicemente, in quest'altro modo abbreviato

```
function scalar raddoppia (scalar n)
return n * 2
end function
```

Dopo aver creato la funzione, o averla importata con `include`, con

```
eval raddoppia(6)
```

otteniamo e scriviamo il risultato 12.

Un esempio meno banale, utile soprattutto per dimostrare come GRETL gestisca la ricorsività, quello di una funzione per il calcolo del fattoriale di un numero:

```
function scalar fattoriale (scalar n)
  if n == 0
    return 1
  else
    return n * fattoriale(n-1)
  endif
end function
```

Ho utilizzato le indentazioni per rendere più leggibile il codice. Si tratta di una cosa non necessaria.

Questo esempio serve anche per spiegare come mai GRETL non preveda una funzione pre-costituita per calcolare il fattoriale: perché sarebbe una funzione che genererebbe spesso risultati sbagliati.

Come abbiamo visto nel Capitolo 4, infatti, GRETL tratta tutti i dati numerici, interi compresi, come numeri a virgola mobile in doppia precisione.

Ciò fa sì che grandi interi, che in altri linguaggi di programmazione come C, C++ e Pascal, genererebbero stack overflow, in GRETL vengono comunque trattati in notazione decimale a virgola mobile ma sono esatti solo fino alla sedicesima cifra compresa.

Per un software che tratta di econometria, dove i numeri possono essere sì molto grandi, ma vengono sempre trattati in scala ridotta (in milioni, o addirittura in miliardi), la precisione a 16 cifre è più che sufficiente, ma non è sufficiente per tutti i calcoli, come quello per il fattoriale.

Un esempio per chiarire.

Il fattoriale di 25 è 15511210043330985984000000 e lo possiamo calcolare esattamente con un linguaggio come Python o Julia, dove gli interi sono o possono essere trattati in precisione arbitraria, cioè praticamente senza limiti, se non quelli imposti dall'hardware.

Se lo calcoliamo in GRETL utilizzando la funzione costruita sopra, con stampa formattata

```
printf "%30.0f\n", fattoriale(25)
```

otteniamo il risultato 15511210043330990350270464.

Sempre un bell'intero di 26 cifre ma le cifre esatte sono solo le prime 16, con la sedicesima arrotondata.

7 Grafica

Come accennato alla fine del Paragrafo 2, GRETTL si appoggia al software esterno Gnuplot per illustrare graficamente i dati in suo possesso.

Abbiamo innanzi tutto la possibilità di accedere direttamente a Gnuplot da GRETTL per costruire un grafico qualsiasi, indipendentemente dai dati in possesso di GRETTL, per esempio per creare il grafico di una qualsiasi funzione matematica.

Dall'interfaccia grafica, agendo con STRUMENTI ▷ GNUPLOT possiamo aprire un terminale Gnuplot in cui lavorare con il linguaggio che Gnuplot capisce oppure, agendo su STRUMENTI ▷ DISEGNA UNA CURVA possiamo lavorare con Gnuplot guidati da un interprete grafico e senza conoscere il linguaggio di Gnuplot.

Se oggetto della grafica sono dati caricati su GRETTL possiamo lavorare dal terminale di GRETTL con il comando `gnuplot`, che ha la seguente sintassi

```
gnuplot <variabili_y> <variabile_x> <opzioni>
```

dove le <variabili_y> sono la variabile o le variabili dipendenti riferite sull'asse delle ordinate e la <variabile_x> è la variabile assunta come variabile indipendente e riferita sull'asse delle ascisse.

Le <opzioni>, per la cui illustrazione rimando alla Guida comandi accessibile dalla GUI di GRETTL, possono servire per indicare le caratteristiche del grafico.

A grafico creato, comunque, cliccando destro su di esso apriamo un menu grazie al quale, cliccando su MODIFICA, abbiamo la possibilità di intervenire sull'estetica del grafico, sul suo titolo, sui titoli e le etichette degli assi, ecc.

La creazione dei grafici diventa più semplice utilizzando dalla GUI di GRETTL il menu VISUALIZZA ▷ GRAFICO o VISUALIZZA ▷ GRAFICI MULTIPLI.

8 Esempi di calcoli ed elaborazioni

Quanto indicato nei precedenti paragrafi, sorretto dalla consultazione delle Guide ai comandi e alle funzioni, ci mette in grado di utilizzare GRETTL per fare moltissime cose, da calcoli più o meno banali alle più sofisticate elaborazioni statistiche o econometriche. Ovviamente, per queste ultime, essendo dotati della preparazione necessaria nelle specifiche materie.

8.1 Calcoli generici

Comprendo in questa categoria tutti i calcoli aritmetici, matematici e di algebra lineare per i quali non esistono voci di menu nell'interfaccia grafica e che possono essere eseguiti ricorrendo necessariamente al terminale o allo scripting.

Come avviene per tutti i linguaggi di scripting dotati di una shell (penso soprattutto a quelli votati al calcolo come Python o Julia) GRETTL può innanzi tutto essere una formidabile calcolatrice, oltre tutto facile da usare grazie alla semplicità della sintassi dei suoi comandi e delle sue funzioni.

Rammento che, per far comparire a terminale i risultati delle elaborazioni, i comandi e le funzioni utilizzate vanno preceduti dal comando `eval`. Cosa non necessaria negli script quando questi risultati vengono assegnati a variabili.

Utilizzando gli operatori aritmetici eseguiamo i più semplici calcoli:

```
eval 3.5 * 4 ritorna 14
```

```
eval 4 ^ 2 ritorna 16
```

```
eval 27 ^ (1/3) ritorna 3
```

```
eval 3 * 2 + 4 ritorna 10
```

```
eval 14 / 3 ritorna 4,6666667
```

Utilizzando anche le numerose funzioni che abbiamo a disposizione possiamo divertirci.

```
eval cos($pi) utilizza le funzioni cos e $pi e ritorna -1
```

`eval sin($pi/2) + 2` utilizza analoghe funzioni e alcuni operatori e ritorna 3
`eval log(5)` oppure `eval ln(5)` ritorna 1,6094379
`eval log10(5)` ritorna 0,69897
`eval det({3, 2; 4, 1})` ritorna -5
`eval inv({2, -1, 0; 0, 3, 2; 5, 0, 3}) * {2; 16; 21}`
 risolve il sistema di equazioni lineari

$$\begin{cases} 2x_1 - x_2 = 2 \\ 3x_2 + 2x_3 = 16 \\ 5x_1 + 3x_3 = 21 \end{cases}$$
 ritornando il vettore colonna delle soluzioni

$$\begin{pmatrix} 3 \\ 4 \\ 2 \end{pmatrix}$$
 secondo il noto procedimento

$$X = M^{-1}N$$
 dove X è il vettore delle soluzioni, M è la matrice dei coefficienti delle incognite (M^{-1} ne è l'inversa) e N è il vettore colonna dei termini noti.
`eval polroots({-2, 3})`
 risolve l'equazione

$$3x - 2 = 0$$
 ritornando la soluzione 0,66667
 L'argomento della funzione è il vettore riga dei coefficienti delle potenze decrescenti del polinomio ordinati alla rovescia.
`eval polroots({-5, 3, 4})`
 risolve l'equazione

$$4x^2 + 3x - 5 = 0$$
 ritornando il vettore colonna delle uniche due radici reali

$$\begin{pmatrix} 0,80425 \\ -1,5542 \end{pmatrix}$$
`eval polroots({-2, 0, 3, 0, 5})`
 risolve l'equazione

$$5x^4 + 3x^2 - 2 = 0$$
 (notare l'inserimento del valore 0 come coefficiente delle potenze mancanti)
 ritornando la matrice delle radici

$$\begin{pmatrix} -0,63246 & 0,0000 \\ 0,63246 & 0,0000 \\ 0,0000 & -1,0000 \\ 0,0000 & 1,0000 \end{pmatrix}$$
 nella quale la parte reale delle radici è nella prima colonna e nella seconda c'è la parte immaginaria. Dove la parte immaginaria è 0 siamo in presenza di radici reali.
`eval easterday(2026)`
 ritorna lo scalare 4,05
 che indica la data della Santa Pasqua dell'anno in cui scrivo: 5 aprile
 (lo scalare ritornato è costituito da mese + giorno/100, per cui la parte intera dello scalare indica il mese e la parte decimale il giorno, facendo attenzione che il giorno 1 viene indicato come 01 e 10 viene indicato come 1, così come il giorno 2 viene indicato come 02 e 20 viene indicato come 2).
 Per esempio `eval easterday(2025)` ritorna 4.2 che significa 20 aprile.

8.2 Calcoli statistici

Anche per i calcoli statistici abbiamo a disposizione una nutrita serie di funzioni utilizzabili da terminale, alcune utilizzabili in maniera più comoda da interfaccia grafica.

Gli argomenti da passare alle funzioni statistiche possono essere passati prendendoli dal dataset caricato nei modi visti nel Capitolo 3.

Prendiamo, per esempio, la più banale funzione statistica `mean()`, che calcola la media avendo come argomento un vettore o una serie.

Con

```
eval mean({3, 4, 5})
```

calcoliamo la media (4) dei tre valori contenuti nel vettore passato come argomento.

Il vettore passato nell'esempio è un vettore riga ma sarebbe lo stesso con il vettore colonna `{3; 4; 5}`.

Se abbiamo caricato il piccolo dataset contenente redditi e consumi in un triennio, che abbiamo già utilizzato per parlare delle serie,

	reddito	consumo
2015	198	135
2016	201	136
2017	212	138

possiamo creare la serie

```
series R = reddito
```

e poi calcolare la media del reddito con

```
eval mean(R)
```

oppure, in maniera ancor più diretta, passando come argomento alla funzione `mean()` il titolo della colonna del dataset di cui vogliamo calcolare la media con

```
eval mean(reddito)
```

in entrambi i casi ottenendo il risultato 203,83333.

Ciò vale per le altre funzioni statistiche più ricorrenti `sd()` (per lo scarto quadratico medio), `var()` (per la varianza), `median()` (per la mediana), `min()` (per il valore minimo), `max()` (per il valore massimo), ecc.

Utilizzando l'interfaccia grafica possiamo ottenere statistiche sui dati del dataset caricato agendo sul menu **VISUALIZZA** > **STATISTICHE DESCRITTIVE** e scegliendo nella successiva finestra di dialogo la serie per la quale vogliamo visualizzare le statistiche, ulteriormente potendo scegliere tra **SOLO STATISTICHE PRINCIPALI** (media, minimo, massimo e scarto quadratico medio) e **STATISTICHE DESCRITTIVE COMPLETE** (media, mediana, minimo, massimo, scarto quadratico medio, coefficiente di variazione, asimmetria, curtosi).

Altra importante funzione statistica è `corr()`, che restituisce l'indice di correlazione di Pearson. Essa funziona esattamente come quelle viste prima, avendo ovviamente bisogno di due argomenti, corrispondenti ai due vettori o alle due serie in riferimento alle quali si vuole valutare l'esistenza di una correlazione lineare

```
eval corr({3,4,5}, {4,7,9}) restituisce 0,99339927
```

```
eval corr(reddito, consumo) restituisce 0,98745886
```

Da interfaccia grafica possiamo ottenere quest'ultimo risultato agendo sul menu **VISUALIZZA** > **MATRICE DI CORRELAZIONE** e scegliendo nella successiva finestra di dialogo le serie da sottoporre a verifica.

Altro importante blocco di funzioni è quello che GRETL dedica alla statistica inferenziale.

Se lavoriamo su terminale a riga di comando abbiamo a disposizione, tra le altre, le funzioni `cdf()` per calcolare funzioni di ripartizione, `critical()` per calcolare i valori critici,

`pvalue()` per calcolare il p-value.

Il primo argomento da indicare tra le parentesi tonde è un carattere che identifica la distribuzione di riferimento (ad esempio `n` per la distribuzione normale, `t` per la distribuzione del test `t` di Student, `f` per la distribuzione del test `F` di Snedecor, ecc.).

Per la completa descrizione di queste funzioni e degli argomenti che esse richiedono rimando alle chiarissime indicazioni in lingua italiana accessibili da menu AIUTO ▷ GUIDA FUNZIONI ▷ PROBABILITÀ.

Se lavoriamo su interfaccia grafica abbiamo sicuramente un più agevole accesso a queste funzioni agendo sul menu STRUMENTI e poi su TAVOLE STATISTICHE, CALCOLA P-VALUE, GRAFICI DI DISTRIBUZIONE e CALCOLA TEST.

Per i valori critici scegliamo il menu STRUMENTI ▷ TAVOLE STATISTICHE, poi selezioniamo la scheda relativa alla distribuzione che ci interessa e inseriamo i richiesti valori.

Per la funzione di ripartizione e il p-value scegliamo da menu STRUMENTI ▷ CALCOLA P-VALUE, poi selezioniamo la scheda relativa alla distribuzione che ci interessa e inseriamo i richiesti valori. Da menu STRUMENTI ▷ GRAFICI DI DISTRIBUZIONE abbiamo modo di ottenere il grafico della distribuzione che ci interessa.

Sempre lavorando su interfaccia grafica, da menu STRUMENTI ▷ CALCOLA TEST abbiamo la possibilità di calcolare i test statistici di più ricorrente uso.

Per un esempio di applicazione di GRETL alla statistica inferenziale propongo questo esercizio.

Per verificare l'efficacia di due sistemi di concimazione dei pomodori sono state piantate 9 piantine della stessa qualità, a gruppi di 3, in tre aiuole a distanza di 4 metri. La prima aiuola e le relative piante sono state trattate con un concime in polvere solubile da applicare ogni settimana, con un certo dosaggio, in soluzione di 10 litri nel terreno e in soluzione da 1 litro a spruzzo sulle foglie (identifichiamo con A questo trattamento). La seconda aiuola è stata trattata con un concime granulare distribuito in un certo dosaggio quindicinalmente sul terreno (identifichiamo con B questo trattamento). Per la terza aiuola non è stato applicato alcun trattamento. In questo modo ciascun gruppo di piante ha avuto tutti gli altri trattamenti di irrigazione, di diserbaggio, ecc. è cresciuto su un terreno omogeneo dal punto di vista della composizione ed è stato esposto agli stessi agenti atmosferici di insolazione, esposizione alla pioggia, ecc. Unica differenza quella del trattamento di concimazione. I primi 6 pomodori venuti a maturazione in ciascun gruppo di piante sono stati pesati ottenendo i seguenti risultati in grammi, inseriti in un file `pomodori.csv`

concime_A	concime_B	no_concime
58	49	41
54	55	53
58	59	39
48	63	53
67	58	41
69	43	46

La nostra verifica consiste nello stabilire se la differenza di peso riscontrata tra i pomodori provenienti dalle varie aiuole possa essere dovuta ad efficacia della concimazione o meno.

Prima cosa da fare è caricare il dataset e, lanciato GRETL, lo facciamo da menu FILE ▷ APRI DATI ▷ FILE UTENTE...

Ora sintetizziamo i dati calcolandone medie e varianze e lo facciamo da terminale con questi comandi

`eval mean(concime_A)`, che ritorna 59, media del campione concimato A,

`eval var(concime_A)`, che ritorna 62,4, varianza del campione concimato A,


`eval mean(concime_B)`, che ritorna 54,5, media del campione concimato B,

`eval var(concime_B)`, che ritorna 53,5, varianza del campione concimato B,

`eval mean(no_concime)`, che ritorna 45,5, media del campione non concimato,
`eval var(no_concime)`, che ritorna 39,1, varianza del campione non concimato.³

Esaminando a occhio questi dati siamo portati a concludere che entrambe le concimazioni, ma specialmente quella denominata A, hanno avuto effetto.

Ciò sembrerebbe confermato anche dall'esame di questo grafico, che creiamo da menu VISUALIZZA ▸ GRAFICO ▸ BOXPLOT..., un tipo di grafico particolarmente adatto al nostro dataset



I box creati, uno per ciascun campione, si estendono dal primo quintile al terzo quintile, il simbolo + all'interno di ciascun box indica la media dei dati e la linea orizzontale all'interno di ciascun box indica la mediana.

Le linee che vediamo sopra ciascun box si estendono fino al valore massimo dei dati del campione rappresentato dal box e le linee che vediamo sotto ciascun box si estendono fino al valore minimo. Il titolo del grafico e la descrizione dell'asse delle ordinate sono stati inseriti, previa apertura del menu cliccando sull'icona, in basso a destra, contrassegnata da tre barrette orizzontali sovrapposte.

Ma per evitare i giudizi a occhio esistono i test statistici.

Il test determinante è quello per verificare se la differenza tra le medie rilevate nei campioni è significativa o può semplicemente essere dovuta al caso. Per questa valutazione sappiamo che esiste il test t di Student.

Ma prioritariamente è bene sottoporre a test per la significatività della differenza la varianza. E questa valutazione la possiamo fare con il test F di Snedecor.

Cominciamo da quest'ultimo.

Da menu STRUMENTI ▸ CALCOLA TEST apriamo una finestra di dialogo attraverso la quale possiamo accedere a più schede che ci guidano al calcolo di test statistici. Per la nostra attuale esigenza apriamo la scheda intitolata 2 VARIANZE, che si presenta così

³Notare come GRETL, sapendo che siamo su un computer italiano, ci ritorni i dati con la virgola come separatore decimale. Non illudiamoci: quando inseriamo noi dati per lui, dobbiamo usare come separatore decimale il punto.

gretl: calcola test

Media Varianza Proporzione 2 medie **2 varianze** 2 proporzioni

☐ Usa variabile dal dataset concime_A

Varianza del campione 1

Dimensione del campione 1

☐ Usa variabile dal dataset concime_B

Varianza del campione 2

Dimensione del campione 2

H0: rapporto tra le varianze = 1

☒ Mostra il grafico della distribuzione campionaria

Aiuto Chiudi OK

Eseguiamo la prima verifica confrontando la varianza del campione concimato A con quella del campione non concimato.

Pertanto selezioniamo il primo USA VARIABILE DAL DATASET e lasciamo la scelta CONCIME_A e poi selezioniamo il secondo USA VARIABILE DAL DATASET e poi scorriamo sulla scelta NO_CONCIME. Lasciamo selezionata, o selezioniamo, l'opzione MOSTRA IL GRAFICO DELLA DISTRIBUZIONE CAMPIONARIA.

Cliccando su OK otteniamo il risultato del confronto in questa finestra

gretl: test di ipotesi

Ipotesi nulla: le varianze delle popolazioni sono uguali

Campione 1:
n = 6, varianza = 62,4

Campione 2:
n = 6, varianza = 39,1

Statistica test: $F(5, 5) = 1,59591$

P-value a due code = 0,6205
(a una coda = 0,3102)

nella quale viene visualizzato il valore del test F di Snedecor (il cui calcolo, per la verità, non aveva bisogno di tutto questo apparato, in quanto il valore del test è semplicemente il rapporto tra le due varianze messe a confronto) arricchito del relativo p-value, il cui valore è alquanto elevato e ci porta ad accettare l'ipotesi nulla, cioè a ritenere che la differenza tra le due varianze sia accidentale e statisticamente non rilevante.


Possiamo averne conferma se calcoliamo il valore critico del test F in presenza dei gradi di libertà riferiti ai nostri piccoli campioni.

Lo potremmo fare da menu STRUMENTI ► TAVOLE STATISTICHE selezionando la scheda F in cui inserire i dati richiesti, ma lo possiamo anche fare più semplicemente a terminale con il comando `eval critical(f, 5, 5, 0.025)`

dove il primo parametro indica la scelta del test F, i successivi due parametri sono i gradi di libertà dei due campioni e l'ultimo parametro è la probabilità a una coda per ottenere una probabilità a due code di 0.05, cioè un risultato attendibile al 95%.

Il valore critico che otteniamo è 7,1463818, di molto superiore al valore del test, a conferma del fatto che va accettata l'ipotesi nulla.

Tutto ciò è visivamente desumibile dal grafico della nostra distribuzione campionaria



nel quale vediamo come il nostro test F del valore di 1,59591, indicato dalla barra rossa verticale, sia sicuramente localizzato nell'area di accettazione dell'ipotesi nulla.

Alle stesse conclusioni arriviamo se ripetiamo il confronto tra la varianza del campione concimato B e quella del campione non concimato.

Ora possiamo affrontare il decisivo confronto tra le medie.

Da menu STRUMENTI ▸ CALCOLA TEST apriamo la finestra di dialogo da cui, questa volta, apriamo la scheda intitolata 2 MEDIE e, con lo stesso procedimento con cui abbiamo prima instaurato il confronto tra varianze, instauriamo il confronto tra la media del campione concimato A con la media del campione non concimato.


Nella finestra, visti i risultati dei confronti tra le varianze, selezioniamo l'opzione ASSUMI CHE LO SCARTO QUADRATICO MEDIO SIA COMUNE TRA LE POPOLAZIONI.

Il valore del test t risulta essere 3,28229, contro un valore critico 2,22814 con probabilità a due code 0.05 (attendibilità al 95%) e un valore critico 3,16927 con probabilità a due code 0.01 (attendibilità al 99%).

Dal momento che il valore del test supera in entrambi i casi il valore critico dobbiamo concludere con il respingere l'ipotesi nulla e ammettere che la differenza tra le medie è statisticamente significativa e non può essere attribuita al caso.

Il che significa che il trattamento di concimazione A ha sicuramente avuto effetto.

Lo possiamo vedere chiaramente anche dal grafico della distribuzione del test t campionario



nel quale vediamo come il nostro test t del valore di 3,28229, indicato dalla barra rossa verticale, sia sicuramente localizzato fuori dall'area di accettazione dell'ipotesi nulla.

Con lo stesso procedimento possiamo instaurare il confronto tra la media del campione concimato B con la media del campione non concimato.

Questa volta il test t risulta essere del valore di 2,29093, sempre contro il valore critico 2,22814 con probabilità a due code 0.05 (attendibilità al 95%) e il valore critico 3,16927 con probabilità a due code 0.01 (attendibilità al 99%).

Il valore del test supera di pochissimo il valore critico con probabilità 0.05 e non supera quello con probabilità 0.01.

Possiamo pertanto scartare con molta cautela l'ipotesi nulla e non è possibile ammettere con la stessa sicurezza di prima che anche il tipo di concimazione B abbia avuto effetto.

Certo non ci ha aiutati in questa indagine il ridottissimo numero degli elementi dei campioni: se avessimo pesato qualche pomodoro in più avremmo probabilmente ottenuto, anche nel secondo raffronto, un risultato meno incerto.

8.3 Calcoli econometrici

Per le elaborazioni di econometria abbiamo a disposizione molti comandi eseguibili da terminale ma è molto più comodo lavorare da interfaccia grafica, dove siamo meglio guidati nella scelta delle varie opzioni con cui impostare le elaborazioni e possiamo con più facilità passare alle rappresentazioni grafiche di ciò che stiamo facendo.

I comandi a disposizione per queste elaborazioni sono ben descritti nella Guida comandi, nella sezione Stima.

Nell'interfaccia grafica la voce di menu dove troviamo gli strumenti econometrici è MODELLO. Una volta scelto un modello si apre una finestra di dialogo da cui avviare l'elaborazione, finestra che ha sempre un pulsante AIUTO, cliccando sul quale abbiamo accesso ad una guida sempre molto ben fatta e in lingua italiana.


Per una esemplificazione di ciò che possiamo fare ho scelto di lavorare con un dataset che troviamo tra i file che fanno parte della dotazione di GRETL. Si tratta della serie storica di reddito e consumo USA tra il 1950 e il 1985.

Carichiamo il dataset da menu FILE ▸ APRI DATI ▸ FILE DI ESEMPIO... andando a scegliere, nella scheda Greene, il file GREENE11_3 AGGREGATE CONSUMPTION AND INCOME DATA.

Una volta caricato il file vediamo che si compone di due serie, una denominata Y, che rappresenta il reddito (aggregate income), l'altra denominata C, che rappresenta il consumo (aggregate consumption).

Possiamo vedere i dati selezionando entrambe le serie nella finestra di lavoro di GRETL e poi da menu DATI ▸ MOSTRA VALORI.

Possiamo vederne il grafico da menu VISUALIZZA ▸ GRAFICO ▸ SERIE STORICA, selezionando entrambe le variabili nella finestra di dialogo che si apre e dando OK. Il risultato è questo



Abbiamo l'andamento della variabile C in rosso (consumo) che segue come una fedele ombra la variabile R in azzurro (reddito).

Poniamo ora di essere all'inizio dell'anno 1986 e di voler fare una previsione sullo sviluppo dei consumi nel prossimo triennio.

Dal momento che, in economia, ciò che succede ad una variabile al tempo t , in assenza di elementi perturbatori o modificatori, è sempre fortemente influenzato da ciò che è successo al tempo $t - 1$, la via più rapida potrebbe essere quella di affidare questa previsione ad un modello autoregressivo applicato alla serie storica del consumo.

GRETL, tra i suoi strumenti della specie, ha il modello ARIMA (AutoRegressive Integrated MovingAverage).

Possiamo utilizzarlo da interfaccia grafica andando su menu MODELLO ▸ SERIE STORICHE UNIVARIATE ▸ ARIMA oppure da terminale con il comando `arima`.

Dobbiamo innanzi tutto adattarlo alla nostra serie storica e lo possiamo fare comodamente ricorrendo al terminale, che apriamo da menu STRUMENTI ▸ TERMINALE DI GRETL, utilizzando il comando `arima` che ha la seguente sintassi

```
arima p d q ; <variabile>
```

L'adattamento consiste nel trovare il valore dei parametri p , d e q che meglio interpretano la serie storica:

- . p (altrimenti detto AR) rappresenta l'ordine dei termini autoregressivi,
- . d (altrimenti detto I) rappresenta l'ordine di differenziazione,
- . q (altrimenti detto MA) rappresenta l'ordine dei termini a media mobile.

Facciamo un primo tentativo attribuendo valore 1 a p , valore 0 a d e valore 1 a q con il comando `arima 1 0 1; C`

La risposta a terminale comprende un sacco di dati che dicono tantissime cose utili agli esperti. Noi principianti ci limitiamo alle cose più vistose e facili da capire.

Nella zona centrale della risposta abbiamo queste indicazioni

	coefficiente	errore std.	z	p-value	
const	1528,23	767,550	1,991	0,0465	**
phi_1	0,996730	0,00460524	216,4	0,0000	***
theta_1	0,737274	0,121206	6,083	1,18e-09	***

e notiamo un errore standard molto elevato in corrispondenza di const, evidenziato anche dal valore del test z e del suo p-value, alquanto elevato. Per i più distratti, in corrispondenza a questa riga abbiamo solo due asterischi al posto dei tre che abbiamo sulle altre righe.

Dobbiamo almeno fare in modo che anche questa riga porti tre asterischi e tentiamo di farlo portando a 2 l'ordine dei termini autoregressivi con il comando

```
arima 2 0 1; C
```

Nella risposta a terminale la zona centrale diventa questa


	coefficiente	errore std.	z	p-value	
const	1898,79	393,547	4,825	1,40e-06	***
phi_1	1,99751	0,00180233	1108	0,0000	***
phi_2	-0,999585	0,000520514	-1920	0,0000	***
theta_1	-0,999964	0,0792117	-12,62	1,56e-36	***

e notiamo un errore standard praticamente dimezzato, con un p-value del test z praticamente azzerato, successo dimostrato dall'ottenimento dei tre asterischi anche su questa riga.

Per il nostro esercizio direi che ci possiamo accontentare e basarci sul modello ARIMA a 2, 0, 1.

Ora possiamo proseguire per arrivare alla previsione lanciando il modello da interfaccia grafica da menu MODELLO ▷ SERIE STORICHE UNIVARIATE ▷ ARIMA.

Nella finestra di dialogo che si apre inseriamo C come variabile dipendente, e i valori 2 nella finestrella AR, 0 nella finestrella I e 1 nella finestrella MA ed otteniamo così una schermata che è simile all'ultima risposta a terminale di prima, con il vantaggio che questa finestra ha una barra di menu da cui, per esempio, possiamo vedere graficamente quale sia la rispondenza del nostro modello nell'interpretare la serie storica del consumo da menu GRAFICI ▷ VALORI EFFETTIVI E STIMATI ▷ RISPETTO AL TEMPO



Confortati anche da questo grafico, affidiamo allora la previsione dei consumi nel prossimo triennio 1986, 1987, 1988 a questo modello.

Lo facciamo dalla schermata del modello da menu ANALISI ▷ PREVISIONE..., inserendo, nella successiva finestrella di dialogo, 3 nella finestrella NUMERO DI OSSERVAZIONI DA AGGIUNGERE.

Possiamo accettare inalterata la successiva finestra di dialogo e, dando OK, otteniamo una finestra nella quale viene indicata la cercata previsione come punto centrale di un intervallo entro il quale si può collocare il valore previsto con probabilità pari a 0,95


Per intervalli di confidenza al 95%, $z(0,025) = 1,96$

	C	Previsione	Errore std	Intervallo al 95%
1986		2364,53	25,0189	2315,49 - 2413,56
1987		2415,47	35,3386	2346,20 - 2484,73
1988		2465,31	43,1977	2380,64 - 2549,98

L'esercizio che abbiamo svolto ha previsto lo sviluppo dei consumi basandosi su un modello autoregressivo dei consumi stessi.

Sappiamo, tuttavia, che i consumi sono strettamente correlati al reddito, anzi, i consumi esistono solo se c'è reddito, cioè sono funzione del reddito e lo si vede bene dal grafico che, a pagina 23, illustra le serie storiche del reddito e del consumo che abbiamo nel nostro dataset.

Lo vediamo ancor meglio dal grafico che possiamo creare da menu VISUALIZZA ► GRAFICO ► X-Y A DISPERSIONE, mettendo sull'asse delle X la variabile Y (reddito) e sull'asse delle Y la variabile C (consumo)



Il grafico riporta anche l'equazione della retta di regressione che evidenzia il legame funzionale esistente tra consumo e reddito secondo un altro modello che GRETL ci consente di utilizzare, il così detto modello OLS (Ordinary Least Square) che troviamo, nell'interfaccia grafica, da menu MODELLO ► MINIMI QUADRATI ORDINARI e che possiamo lanciare da terminale con il comando `ols` con la seguente sintassi

`ols <variabile_dipendente> <variabili_indipendenti>`

inserendo, tra le due variabili, il valore 0 se si vuole calcolare il termine costante, altrimenti detto intercetta.

Notare come <variabili_indipendenti> sia al plurale, ad indicare che il modello si presta anche alla regressione multipla.

Avendo caricato il nostro dataset su reddito e consumi, con il comando a terminale

`ols C 0 Y`

otteniamo una risposta che comprende questa zona

	coefficiente	errore std.	rapporto t	p-value
const	11,3737	9,62946	1,181	0,2457
Y	0,898329	0,00584839	153,6	6,61e-50 ***

nella quale notiamo come la retta interpolante con intercetta, che viene per default calcolata nel grafico, non sia forse il meglio per interpretare la relazione esistente tra reddito e consumo.

Forse è migliore la retta senza intercetta con il coefficiente angolare che calcoliamo con il comando

```
ols C Y
```

ottenendo in risposta

	coefficiente	errore std.	rapporto t	p-value
Y	0,904860	0,00191589	472,3	3,54e-68 ***

da cui la retta dei minimi quadrati diventa $C = 0,904860Y$.

Per prevedere il consumo dei prossimi tre anni con questo modello che fa dipendere il consumo dal reddito dobbiamo predisporre una previsione del reddito per i prossimi tre anni e, se non abbiamo altre fonti più attendibili per farlo, dobbiamo ricorrere ad un modello autoregressivo come ARIMA.

Ripetendo il procedimento applicato prima per l'autoregressione sul consumo alla serie storica del reddito, ancora una volta troviamo che la migliore interpretazione dell'andamento del reddito si ottiene con un modello ARIMA con AR pari a 2, I pari a 0 e MA = 1, con la seguente previsione

Per intervalli di confidenza al 95%, $z(0,025) = 1,96$				
	Y	Previsione	Errore std	Intervallo al 95%
1986		2555,84	29,9527	2497,14 - 2614,55
1987		2600,63	42,2844	2517,76 - 2683,51
1988		2643,25	51,6469	2542,02 - 2744,47

La previsione del consumo basata su questa previsione del reddito si può ottenere semplicemente moltiplicando per 0,904860 i valori del reddito previsto, secondo la relazione determinata prima.

Se vogliamo una indicazione comprensiva dell'intervallo di confidenza dobbiamo inserire la previsione dei redditi nel dataset agendo da menu DATI ▷ MODIFICA VALORI con selezionata la variabile Y nel foglio di lavoro di GRETl e inserendo i dati nella specie di foglio elettronico che ci si presenta, confermando alla fine con click sul segno di spunta nella barra degli strumenti.

Lanciamo ora il modello da menu MODELLO ▷ MINIMI QUADRATI ORDINARI, indicando la C come variabile dipendente e la Y come regressore (senza la const) e, agendo da menu ANALISI ▷ PREVISIONE nella finestra dei risultati, arriviamo a questa previsione del consumo

Per intervalli di confidenza al 95%, $t(35, 0,025) = 2,030$				
	C	Previsione	Errore std	Intervallo al 95%
1986		2312,64	19,5504	2272,95 - 2352,33
1987		2353,18	19,5720	2313,45 - 2392,91
1988		2391,73	19,5930	2351,95 - 2431,50

Rispetto alla previsione ottenuta con l'autoregressione sulla serie storica dei consumi che qui riporto per facilità di raffronto

Per intervalli di confidenza al 95%, $z(0,025) = 1,96$				
	C	Previsione	Errore std	Intervallo al 95%
1986		2364,53	25,0189	2315,49 - 2413,56
1987		2415,47	35,3386	2346,20 - 2484,73
1988		2465,31	43,1977	2380,64 - 2549,98

essa è più conservativa ma, a giudicare dall'errore standard, pare più attendibile, come, peraltro, dovrebbe essere se teniamo conto della subordinazione della variabile consumo rispetto alla variabile reddito.

* * *

Gli esempi che ho proposto sono tutti impostati su un rapporto interattivo con GRETL.

Numerosi esempi di script, per chi fosse interessato a questo tipo di approfondimento, vengono installati insieme a GRETL e, nel sistema Windows, si trovano nella directory di installazione, sottodirectory `scripts`, mentre in Linux e Mac si trovano in `usr/share/gretl/scripts`.

Lo script è un file con estensione `.inp` cliccando sul quale si apre l'editor degli script che ne mostra il contenuto.

Cliccando sulla sesta icona da sinistra della barra degli strumenti dell'editor, quella con il simbolo degli ingranaggi, lo script viene eseguito.